

АНОТАЦІЯ

Тимченко Б. І. Нейромережеві методи аналізу планарних зображень в системах автоматизованого скринінгу. — Кваліфікаційна наукова праця на правах рукопису.

Дисертація на здобуття наукового ступеня доктора філософії за спеціальністю 122 — Комп'ютерні науки. — ІКС ОНПУ, Одеса, 2021.

У **вступі** обґрунтовано актуальність удосконалення систем автоматизованого скринінгу (виявлення та класифікації нетипових об'єктів або процесів) шляхом створення моделей наборів даних та методів їх генерації, а також моделей нейронних мереж та методів багатозадачного навчання з метою підвищення достовірності класифікації та сегментації планарних зображень без підвищення витрат часу. Визначено об'єкт, предмет, задачі і методи дослідження; показано зв'язок з науково-дослідними роботами; наведено наукову новизну та практичне значення одержаних результатів; висвітлено особистий внесок здобувача.

В **першому розділі** дисертаційної роботи проведено аналіз проблем аналізу планарних зображень (які не мають виміру глибини, та в яких можна знехтувати масштабом об'єктів) в системах автоматизованого скринінгу на основі нейромережевих технологій.

Проаналізовано існуючі системи автоматизованого скринінгу в предметних областях медицини, метеорології та віддаленого зондування та особливості їх функціонування шляхом аналізу планарних зображень. Показано, що ефективність роботи таких систем безпосередньо залежить від достовірності класифікації та сегментації зображень, оскільки хибно-позитивні результати можуть призвести до передчасного реагування, а хибно-негативні

результати - до пропуску наявних проблем та пізнього реагування. Крім того, не менш важливим фактором, що впливає на ефективність скринінгових систем є витрати часу на реалізацію процесу навчання, що в свою чергу пов'язано з якістю попередньо створених навчальних вибірок даних. Але, в задачах скринінгу, отримання достатньої кількості даних та проведення якісного анотування професіоналами є, як правило, затратним, а іноді неможливим через малу кількість та різний вигляд навчальних прикладів, суб'єктивність під час формування анотацій в наборах даних. Ці фактори негативно впливають на достовірність класифікації та сегментації при навчанні глибоких нейронних мереж стандартними методами. Для усунення такого впливу запропоновано при побудові моделей класифікації та сегментації вирішити задачу навчання з урахуванням частково-помилкових анотацій.

Показано, що в таких умовах доцільне використання глибоких нейронних мереж, через можливість автоматизації процесу навчання та застосування методів багатозадачного навчання, які підвищують достовірність класифікації та сегментації.

Проведений аналіз наявних моделей наборів даних та методів їх генерації показав обмеженість моделей наборів даних, які б дозволяли формувати частково-помилкові анотації, які характерні для реальних задач автоматизованого скринінгу.

Таким чином, вирішення важливої науково-практичної задачі підвищення достовірності класифікації та сегментації в задачах аналізу планарних зображень для систем автоматизованого скринінгу шляхом удосконалення моделей нейронних мереж та методів їх багатозадачного навчання, особливо за умови частково-помилково анотованих даних навчальної вибірки.

У **другому розділі** розроблено метод генерації наборів даних для забезпечення можливості тестування нейронних мереж при навчанні з використанням частково-помилкових анотацій та запропоновано параметричну

формалізацію моделі набору даних із частково-помилковими анотаціями, які характерні для реальних задач автоматизованого скринінгу.

Оскільки одержання достовірних анотацій класифікації та сегментації для тестувальних вибірок часто є неможливим або дуже затратним, запропоновано використання модельних наборів даних для оцінки достовірності моделей та методів навчання глибоких нейронних мереж. Такі набори даних дають можливість проводити навчання та тестування в контрольованих умовах шляхом штучного додавання помилок до анотацій навчальної вибірки даних (як правило, тестова вибірка залишається з достовірними анотаціями).

Запропонована модель набору даних \mathcal{M} має наступне представлення:

$$\mathcal{M} \in \{\mathcal{X}_b, \mathcal{X}_{tex}, N, S_{img}, S_{obj}, \Delta_{max}, N_{obj}, P_e, P_d, S_e, S_d\} \quad (1)$$

де \mathcal{X}_b - набір зображень фону, \mathcal{X}_f - набір об'єктів, \mathcal{X}_{tex} - набір зображень текстур об'єктів, N - кількість зображень в генерованому наборі даних, S_{img} - розмір генерованих зображень в пікселях, S_{obj} - середній розмір об'єкта в пікселях, Δ_{max} - максимальне відхилення розміру об'єкта в відсотках, N_{obj} - максимальна кількість об'єктів на зображенні, P_e та P_d - ймовірності зменшення та збільшення маски кожного з об'єктів, S_e та S_d - допустимі масштаби збільшення та зменшення масок всіх об'єктів.

Останні чотири параметри введено для контрольованого створення помилок в анотаціях.

Сформульовано **перший пункт наукової новизни**: вперше запропоновано параметричну формалізацію моделі набору даних із частково-помилковими анотаціями, які характерні для реальних задач автоматизованого скринінгу, що дозволило розробити метод генерації навчальних, тестових та валідаційних наборів даних.

На основі запропонованої параметричної моделі (1) розроблено метод

генерації наборів даних із зашумленими анотаціями, який містить наступні кроки:

1. Вибрати випадкове зображення фону: $x_{bg} \sim \mathcal{X}_b$
2. Вибрати кількість об'єктів на зображенні: $N_{obj} \sim \mathcal{U}(1, N_{obj})$
3. Провести ініціалізацію маски сегментації: $M = 0$ так що $M \in \mathcal{R}^{C \times S_{img} \times S_{img}}$
4. Виконати наступні кроки n_{obj} разів:

4.1 Вибрати розміри об'єкта: $s \sim \mathcal{U}(S_{obj} - \Delta_{max}, S_{obj} + \Delta_{max})$

4.2 Вибрати координати розміщення об'єкта:

$$i_f \sim \mathcal{U}(0, S_{img} - s)$$

$$j_f \sim \mathcal{U}(0, S_{img} - s)$$

4.3 Вибрати зображення об'єкта $x_{fg} \sim \mathcal{X}_f$ та відповідний клас об'єкта $c_{fg} \sim \mathcal{Y}_f$

4.4 Змінити розмір зображення об'єкта за допомогою білінійної інтерполяції:

$$\hat{x}_{fg} = R_{bilinear}(x_{fg})$$

4.5 Вибрати зображення текстури $x_{tex} \sim \mathcal{X}_{tex}$

4.6 Модифікувати зображення об'єкта за допомогою текстури:

$$\hat{x}_{fg} = x_{fg} \circ x_{tex}[i_f : i_f + s, j_f : j_f + s]$$

4.7 Розмістити зображення об'єкта на зображенні фону:

$$x_{bg}[i_f : i_f + s, j_f : j_f + s] = (1 - x_{fg}) \circ x_{bg} + \hat{x}_{fg}$$

4.8 Сформувати маску сегментації об'єкта:

$$M_{seg} = x_{fg} > \theta_{seg}$$

де θ_{seg} - поріг бінаризації вихідного зображення об'єкта. Для набору даних MNIST $\theta_{seg} = 0.2$, для набору даних FashionMNIST $\theta_{seg} = 0.1$.

4.9 Модифікувати маску сегментації відповідно до необхідного рівня помилок:

$$M_{seg} = \begin{cases} M_{seg} \oplus K^{S_d \times S_d} & \text{якщо } p_d \sim \mathcal{U}(0, 1) < P_d \\ M_{seg} \ominus K^{S_e \times S_e} & \text{якщо } p_e \sim \mathcal{U}(0, 1) < P_e \end{cases}$$

де $K^{S_d \times S_d}$ - матриця ядра $K^{S_e \times S_e}$ - матриця ядра ерозії.

4.10 Розмістити модифіковану маску сегментації об'єкта на загальному зображенні маски сегментації:

$$M[c_{fg}, i_f : i_f + s, j_f : j_f + s] = \max \{M[c_{fg}, i_f : i_f + s, j_f : j_f + s], M_{seg}\}$$

4.11 Зберегти зображення x_{bg} та маску M

5. Завершити генерацію

Таким чином, удосконалено метод генерації наборів даних із частково-помилковими анотаціями на основі параметричної моделі, що за рахунок що за рахунок генерації анотацій: частково-помилкових для тренувальної вибірки та достовірних - для тестової, дало можливість виконувати тестування впливу рівня помилок анотацій на роботу нейромережових методів сегментації та класифікації.

Метод дозволяє отримати безліч наборів даних із схожими характеристиками та використовувати непараметричні статистичні методи (бутстрепінг) для оцінки моделей в умовах відсутності реальних тренувальних даних. Метод становить **другий пункт наукової новизни**.

В **третьому розділі** дисертаційної роботи розроблено моделі нейронних мереж та методи багатозадачного навчання для одночасного підвищення достовірності класифікації та сегментації без зниження оперативності.

Для реалізації методів багатозадачного навчання, запропоновано удосконалити моделі глибоких нейронної мережі з використанням архітектури енкодер-декодер (UNet, LinkNet) введенням додаткового декодера з додатковим шаром нормалізації. Таким чином, вдосконалена модель склада-

ється з енкодера та двох декодерів (для задач сегментації та класифікації відповідно).

Модель глибокої нейронної мережі представлено наступним виразом:

$$v_1, v_2 \dots v_n = F_{encoder}(x, \theta_{enc}) \quad (2)$$

$$M_{seg} = F_{seg}((v_1, v_2 \dots v_n), \theta_{seg}) \quad (3)$$

$$C_{cls} = F_{cls}((v_n), \theta_{cls}) \quad (4)$$

де θ_{enc} - набір параметрів енкодера, θ_{seg} та θ_{cls} - набори параметрів декодерів сегментації та класифікації відповідно, F_{seg} та F_{cls} - нейронні мережі декодера сегментації та класифікації відповідно. Запропонована модель складає **третій пункт наукової новизни**.

Завдяки введенню додаткового декодера класифікації з шаром нормалізації, з'явилася можливість реалізації методів багатозадачного навчання глибоких нейронних мереж та передбачення результатів.

При практичному використанні нейромережових методів в задачах скринінгу встановлено, що частково-помилкові анотації тренувальних даних заважають отриманню високої достовірності в задачах класифікації та сегментації.

Запропоновано метод багатозадачного навчання нейронних мереж в умовах частково-помилкових анотацій навчальних даних який спирається на використання задач, пов'язаних з оригінальною. Показано, що для задачі сегментації існує близька задача класифікації, для якої анотації навчальних даних є якіснішими, ніж для вихідної задачі сегментації.

Метод багатозадачного навчання складається з двох етапів.

Етап 1: генерація похідної задачі. В контексті багатозадачного навчання, задача класифікації зводиться до визначення набору сегментованих зразків (*англ.* multiple instance learning) на планарному зображенні,

замість маркування кожного з об'єктів для всіх класів. При цьому, анотація вихідного планарного зображення являє собою множину з одним, чи декількома визначеними об'єктами.

Для кожної з задач (класифікація та сегментації) окремо обчислюється функція втрат. Для навчання декодера сегментації використовується обмежена зверху функція втрат L_{seg} , в той час як для декодера класифікації - звичайна L_{cls} , а загальне значення функції втрат визначається як середнє арифметичне між індивідуальними значеннями:

$$L_{total} = \frac{L_{seg} + L_{cls}}{2} \quad (5)$$

Відповідно, загальний градієнт функції втрат буде також середнім арифметичним градієнтів складових частин ∇L_{seg} і ∇L_{cls} :

$$\nabla L_{total} = \frac{\nabla L_{seg} + \nabla L_{cls}}{2} \quad (6)$$

Таким чином, забезпечується наявність ненульових градієнтів для оновлення параметрів від хоча б однієї функції втрат для кожного вхідного прикладу.

Етап 2: Введення обмежень. Для зменшення впливу помилкової частини анотацій, запропоновано ввести обмеження другого роду (зверху) до функції втрат для задачі сегментації з менш якісними анотаціями даних. Що дозволило при навчанні на декількох задачах зменшити вплив градієнтів функції втрат на прикладах з помилковими анотаціями:

$$\mathcal{L} = \min(L, \theta)$$

де θ - поріг обмеження функції втрат.

Таким чином, введені обмеження представлені наступним виразом:

$$\nabla \min(L, \theta) = \begin{cases} 1, & \text{якщо } L \in (-\infty, \theta] \\ 0, & \text{якщо } L \in (\theta, \infty) \end{cases}$$

В умовах відсутності розмітки для прикладів в задачах сегментації, можливе ітеративне уточнення цієї розмітки. Для цього обчислюється уточнена карта ознак класифікації шляхом добутку Адамара між нормованим за допомогою сигмоїдної функції виходом декодера сегментації та логітами класифікації:

$$M_{unsup} = \hat{M}_{seg} \circ C_{cls} \quad (7)$$

Далі, для отримання результату класифікації виконується сумація елементів M_{unsup} з нормалізацією за сумою елементів оригінальної ненормалізованої карти локалізації:

$$C_{unsup} = \frac{\sum_{h=0}^H \sum_{w=0}^W M_{unsup}(h,w)}{\sum_{h=0}^H \sum_{w=0}^W M_{seg}(h,w) + c} \quad (8)$$

На основі запропонованих моделі нейронної мережі та методу її навчання, розроблено метод багатозадачного передбачення. Це дозволило підвищити достовірність класифікації та сегментації планарних зображень без зниження оперативності.

Метод містить наступні етапи:

Етап 1. Нормалізація. Нехай $C_{cls} \in \mathcal{R}^C$ та $M_{seg} \in \mathcal{R}^{C \times H \times W}$ - результати декодерів класифікації та сегментації відповідно, значення яких знаходяться на проміжку $(-\infty, +\infty)$ (логіти).

Для отримання результатів на проміжку $[0, 1]$ використовується логістична сигмоїдна функція активації:

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

Етап 2. Ренормалізація. Ренормалізація полягає у зважуванні карти сегментації за допомогою нормованих логітів класифікатора. Першим кроком є трансформація логітів сегментації та класифікації в некалібровані оцінки на проміжку $[0, 1]$:

$$\hat{M}_{seg} = \sigma(M_{seg})$$

$$\hat{C}_{cls} = \sigma(C_{cls})$$

Ці оцінки мають ті самі розмірності, що й оригінальні маска та класи, для зручності репрезентації операцій додано додаткові розмірності до вектору класів: $\hat{M}_{seg} \in \mathcal{R}^{C \times H \times W}$ та $\hat{C}_{cls} \in \mathcal{R}^{C \times 1 \times 1}$

Зважування карти сегментації відбувається за допомогою добутку Адамара між матрицями \hat{M}_{seg} та \hat{C}_{cls}

$$M_{refined} = \hat{M}_{seg} \circ \hat{C}_{cls}$$

За допомогою моделі протестовано запропоновані методи в різних умовах, виконаний аналіз внеску окремих компонентів та проведено аналіз стійкості запропонованого методу до різних рівнів помилок в анотаціях. В середньому, підвищення коефіцієнта Дайса відносно базової моделі склало 13%.

Таким чином, можна сформулювати **четвертий пункт наукової новизни**, а саме удосконалено методи багатозадачного навчання та передбачення результатів на основі удосконаленої моделі згорткових нейронних мереж шляхом об'єднання класифікації та сегментації і введення обмеження другого роду (зверху) при обчисленні функції втрат сегментації, що дозволило підвищити достовірність сегментації та класифікації в задачах автоматизованого скринінгу.

У **четвертому розділі** розроблені інструментальні засоби, що реалізують запропоновані рішення. Проведено випробування розробленого методу

в рамках експериментів як на синтетичних даних, що були згенеровані за допомогою запропонованої моделі, а також експерименти в реальних задачах: скринінг діабетичної ретинопатії, скринінг меланому, та скринінг хмарних утворень.

Інструментальні засоби розроблено мовою програмування Python з використанням фреймворку автоматичного диференціювання PyTorch. На основі розроблених інструментальних засобів створено ефективні програмні модулі, які інтегровано з “хмарними” сервісами для вирішення ресурсомістких задач навчання нейронних мереж, що забезпечує високу обчислювальну потужність та швидкість прогнозування в задачах автоматизованого скринінгу.

Для задачі автоматизованого скринінгу при сегментації патернів організації хмар на супутникових знімках (в рамках проекту “Understanding Clouds from Satellite Images” на платформі для змагань з наук про дані Kaggle) було використано запропоновані моделі нейронних мереж, а також методи їх навчання та прогнозування результатів. Підвищення достовірності (міра Дайса) відносно базової моделі склало 3.9%.

Для задачі автоматизованого скринінгу при класифікації стадій діабетичної ретинопатії (в рамках проекту “APTOS 2019 Blindness Detection” на платформі для змагань з наук про дані Kaggle) було використано запропоновані методи багатозадачного навчання та прогнозування результатів. Підвищення достовірності (F1-міра) відносно базової моделі склало 2.1%.

Для задачі розпізнавання уражень шкіри при скринінгу меланому (у рамках проекту SIIM-ISIC Melanoma Classification на платформі для змагань з наук про дані Kaggle) було використано запропонований локалізації важливих для класифікації ознак зображення. Використання запропонованого методу дозволило спростити процес контролю навчання нейронних мереж, що допомогло попередити перенавчання і підвищити достовірність класифікації на 3.5%.

Розроблені в роботі методи та інструментальні засоби отримали впровадження в навчальний процес ОНПУ та програмний продукт SafetyRadar компанії VITech Lab, основним призначенням якого є скринінг наявності елементів засобів індивідуального захисту на людях в умовах будівельних майданчиків, або лікарень та лабораторій.

Ключові слова: аналіз зображень, модель даних, глибинні нейронні мережі, багатозадачне машинне навчання, сегментація, класифікація, функції втрат.

ВСТУП

Актуальність теми зумовлюється стрімким розвитком процесів, які потребують швидкого реагування на нетипові зміни для їх подальшого коригування, поки ціна наслідків є низькою. Задача виявлення таких нетипових змін називається задачею скринінгу, особливу групу серед яких складають засновані на аналізі планарних зображень задачі, які виникають, наприклад, при медичній діагностиці, дистанційному зондуванні Землі, метеорології тощо. Автоматизація скринінгу дозволяє з більшою ефективністю вирішувати проблеми підвищення продуктивності діяльності людини-оператора, підвищити рентабельність відповідних процесів.

При автоматизації скринінгу основними процедурами, що визначають його достовірність є сегментація регіонів інтересу та їх класифікація. Традиційно, в таких системах використовуються класичні методи комп'ютерного зору (пошук границь, бінарна сегментація за інтенсивністю, кореляційно-екстремальний метод, тощо), однак достовірність їх суттєво обмежена через різноманіття можливих спотворень (наприклад, різний вигляд об'єктів одного класу) та складність їх формалізації за допомогою наборів простих ознак. В таких умовах доцільне використання семантичної сегментації (*класифікаційного методу сегментації*), для реалізації якої в теперішній час використовуються глибинні нейронні мережі, завдяки можливості вирішення задач в умовах невизначеності та стійкості до вхідних спотворень з високою достовірністю. Безумовною перевагою застосування глибинних нейронних мереж є можливість використання багатозадачного навчання для підвищення достовірності та оперативності, але його застосування потребує наявності великих наборів достовірно анотованих (розмічених) даних.

Але, в задачах скринінгу, отримання достатньої кількості даних та проведення якісного анотування професіоналами є, як правило, затратним, а іноді неможливим через малу кількість та різний вигляд навчальних прикладів, суб'єктивність під час формування анотацій в наборах даних.

Таким чином, має місце **протиріччя** між широкими можливостями щодо забезпечення достовірності рішення задачі автоматизованого скринінгу нейромережевими методами з одного боку, та обмеженістю існуючих методів отримання наборів анотованих даних для навчання глибоких нейронних мереж.

Для розв'язання цього протиріччя в дисертаційній роботі “Нейромережеві методи аналізу планарних зображень в системах автоматизованого скринінгу” запропоновані відповідні нейромережеві моделі та методи аналізу планарних зображень в задачах автоматизованого скринінгу для підвищення його достовірності.

Робота пов'язана з дослідними проектами:

Робота виконана відповідно до планів наукової і науково-технічної діяльності Одеського Національного Політехнічного Університету в рамках держбюджетних науково-дослідних робіт: «Моделі, методи та інструментальні засоби підтримки прийняття рішень з підвищення ефективності гідроаеродинамічних процесів в діючому енергетичному обладнанні» (№ ДР 0115U000413); «Дослідження інформаційних сховищ як моделей предметних областей в системах підтримки прийняття рішень» (№ ДР 0104U002401); «Методи моделювання та робочого діагностування складних цифрових систем і мереж» (номер ДР 0110U008194)

Метою дослідження є підвищення достовірності класифікації та сегментації планарних зображень в системах автоматизованого скринінгу шляхом розробки нейромережових моделей і методів.

Для досягнення мети дослідження необхідно вирішити такі завдання:

— провести аналіз проблем автоматизованого скринінгу, показати пе-

реваги та недоліки нейромережевого підходу, та обґрунтувати напрямки досліджень;

- розробити параметричну модель набору даних, зокрема з частково-помилковими анотаціями, які характерні для реальних задач автоматизованого скринінгу;
- розробити модель нейронної мережі та методи навчання й передбачення для аналізу планарних зображень;
- розробити інструментальні засоби, які реалізують розроблені нейромережеві моделі та методи, та виконати апробацію і впровадження теоретичних результатів при вирішенні завдань автоматизованого скринінгу.

Об'єктом дослідження є процеси аналізу планарних зображень в системах автоматизованого скринінгу.

Предмет дослідження – нейромережеві моделі та методи класифікації і сегментації планарних зображень в задачах автоматизованого скринінгу.

Методи дослідження. Для вирішення поставлених задач використані методи системного аналізу та теорії множин при розробці нейромережевих моделей; теорія нейронних мереж при розробці відповідних нейромережевих моделей та методів; теорія цифрової обробки зображень та розпізнавання при розробці методів класифікації і сегментації; методи імітаційного моделювання при апробації запропонованих рішень.

Наукова новизна отриманих результатів. Основний науковий результат полягає у розв'язанні важливої науково-практичної задачі підвищення достовірності класифікації та сегментації планарних зображень в системах автоматизованого скринінгу шляхом розробки нейромережевих моделей і методів.

У рамках виконаних досліджень отримано такі наукові результати:

- *вперше* запропоновано параметричну формалізацію моделі набору

даних із частково-помилковими анотаціями, які характерні для реальних задач автоматизованого скринінгу, що дозволило розробити метод генерації навчальних, тестових та валідаційних наборів даних;

- *удосконалено* метод генерації наборів даних на основі параметричної моделі, що за рахунок генерації анотацій: частково-помилкових для тренувальної вибірки та достовірних - для тестової, що дало можливість підвищити ефективність тестування нейромережових методів сегментації та класифікації в задачах автоматизованого скринінгу;
- *удосконалено* моделі згорткових нейронних мереж шляхом додавання додаткового декодера класифікації з шаром нормалізації, що дало змогу побудувати методи багатозадачного навчання та передбачення результатів нейронних мереж, які вирішують задачі сегментації та класифікації одночасно;
- *удосконалено* методи багатозадачного навчання та передбачення на основі удосконаленої моделі згорткових нейронних мереж шляхом об'єднання класифікації та сегментації і введення обмеження другого роду (зверху) при обчисленні функції втрат сегментації, що дозволило підвищити достовірність сегментації та класифікації в задачах автоматизованого скринінгу.

Практичне значення одержаних результатів. Практичне значення розроблених моделей та методів підтверджується їх використанням в розроблених інструментальних засобах для вирішення задач автоматизованого скринінгу. Результати дисертаційної роботи впроваджено: в програмний продукт SafetyRadar компанії VITech Lab (акт впровадження від 13.09.2021), xxxxxxxxxxxx, в навчальний процес кафедри Інформаційних систем Інституту Комп'ютерних систем Одеського Національного Політехнічного Університету (акт впровадження від).

На основі розроблених інструментальних засобів створено ефективні програмні модулі, які інтегровано з “хмарними” сервісами для вирішення ресурсомістких задач навчання нейронних мереж, що підвищило оперативність навчання та передбачення в задачах автоматизованого скринінгу на 15Впровадження запропонованих в дисертаційній роботі моделей та методів забезпечує підвищення достовірності сегментації та класифікації планарних зображень в задачах автоматизованого скринінгу та скорочує витрати на одержання анованих наборів даних.

Особистий внесок здобувача

Основні наукові положення, висновки і рекомендації, що містяться в дисертації та виносяться на захист, отримано здобувачем особисто в період з 2016 по 2020 рр. Наукова праця [1] опублікована без співавторів. У статтях, написаних у співавторстві, внесок здобувача полягає в наступному: [2-4] – запропоновано модель нейронної мережі та метод багатозадачного навчання, [5] – запропоновано модель нейронної мережі та метод підбору порогу класифікації, [6-8] – модель нейронної мережі та метод еволюції параметрів, [9] - алгоритм детекції полоси для лінійної камери; [11] – метод ідентифікації параметрів ковзання; [12-13] – метод розпізнавання спектрів.

Апробація результатів дисертації

Основні положення і практичні результати дисертаційної роботи доповідалися та одержали схвалення на таких конференціях: міжнародній науковій конференції з методів розпізнавання патернів “ICPRAM-2020” (м. Валетта, Мальта, 2020), українсько-німецьких науково-практичних конференціях “Інформатика. Культура. Техніка”: ІКТ-2016, ІКТ-2018 (м. Одеса), міжнародних студентських конференціях “Сучасні інформаційні технології”: СІТ-2017, СІТ-2018 (м. Одеса).

Публікації

Основні результати дисертаційної роботи викладено в 13 публікаціях, з них: 8 статей у наукових фахових періодичних виданнях України з техні-

чних наук, 1 стаття у зарубіжному науковоуму періодичному виданні з на-
пряму, з якого підготовлено дисертацію, що індексується наукометричною
базою SCOPUS, 4 публікацій у працях і матеріалах наукових конференцій.

Структура і обсяг роботи

Дисертація складається з вступу, чотирьох розділів, висновків, списку
використаних джерел і додатків. Повний обсяг дисертації складає 180 сто-
рінок, в тому числі: 125 сторінок основного тексту, 59 рисунків і 17 таблиць,
список використаних джерел з 135 найменувань і 2 додатки.