

ОДЕСЬКИЙ НАЦІОНАЛЬНИЙ ПОЛІТЕХНІЧНИЙ УНІВЕРСИТЕТ
ІНСТИТУТ КОМП'ЮТЕРНИХ СИСТЕМ

Кваліфікаційна наукова
праця на правах рукопису

ТИМЧЕНКО Борис Ігорович

УДК 004.932.72'1

ДИСЕРТАЦІЯ

**МЕТОДИ ТА ІНСТРУМЕНТАЛЬНІ ЗАСОБИ ОБРОБКИ
ПЛАНАРНИХ ЗОБРАЖЕНЬ НА ОСНОВІ ШТУЧНИХ
НЕЙРОННИХ МЕРЕЖ В СИСТЕМАХ АВТОМАТИЗОВАНОГО
СКРИНІНГУ**

122 — Комп'ютерні науки
Інформаційні технології

Подається на здобуття наукового ступеня
доктора філософії

Дисертація містить результати власних досліджень. Використання ідей, результатів і текстів інших авторів мають посилання на відповідне джерело.

_____ Б. І. Тимченко

Науковий керівник: **Антощук Світлана Григорівна**,
доктор технічних наук, професор

Одеса — 2021

АНОТАЦІЯ

Тимченко Б. І. Методи та інструментальні засоби обробки планарних зображень на основі штучних нейронних мереж в системах автоматизованого скринінгу. — Кваліфікаційна наукова праця на правах рукопису.

Дисертація на здобуття наукового ступеня доктора філософії за спеціальністю 122 — Комп'ютерні науки. — ІКС ОНПУ, Одеса, 2021.

Ключові слова: .

ABSTRACT

Tymchenko B. I. Methods and tools for processing planar images based on artificial neural networks in automated screening systems. — Qualification scientific work in the form of manuscript.

Thesis for doctor of philosophy degree in speciality 122 — Computer science. — ICS ONPU, Odesa, 2021.

Key words: .

ЗМІСТ

Вступ	7
Розділ 1. Аналіз методів, алгоритмів і програмних засобів обробки планарних зображень	12
1.1. Аналіз задачі автоматизованого скринінгу	12
1.1.1. Задачі автоматизованого скринінгу в медицині	12
1.1.2. Задача автоматизованого скринінгу на виробництві .	16
1.1.3. Задачі автоматизованого скринінгу в метеорології . .	16
1.2. Аналіз методів та алгоритмів обробки зображень	18
1.2.1. Особливості планарних зображень	18
1.2.2. Feature detection	18
1.2.3. Задача класифікації зображень та відомі методи її розв’я- зання	18
1.2.4. Задача семантичної сегментації зображень та відомі методи її розв’язання	18
1.3. Методи глибинного машинного навчання	18
1.3.1. Загальні відомості про штучні нейронні мережі	19
1.3.2. Згорткові нейронні мережі	19
1.3.3. Визначні сучасні архітектури ШНМ класифікації зо- бражень	21
1.3.4. Визначні архітектури ШНМ для сегментації зображень	31
1.4. Трансферне навчання	38
1.5. Методи багатозадачного глибинного машинного навчання .	39
1.5.1. Визначення багатозадачного машинного навчання . .	40
1.5.2. Жорсткий розподіл параметрів	40

1.5.3.	М'який розподіл параметрів	41
1.5.4.	Дистиляція прогнозів моделі	43
1.5.5.	Багатозадачне навчання в задачах класифікації та сегментації	44
1.6.	Аналіз методів оцінки якості класифікації та сегментації зображень в задачі автоматизованого скринінгу	48
1.6.1.	Помилки 1 і 2 роду та матриця невідповідностей	48
1.6.2.	Влучність, чутливість та специфічність	49
1.6.3.	Міра F1 та індекс подібності Соренсена	49
1.6.4.	Каппа Коена	50
1.7.	Висновки та постановка задачі дослідження	51
Розділ 2. Метод глибинного багатозадачного навчання		54
2.1.	Метод багатозадачного навчання ШНМ в умовах частково помилкової розмітки навчального набору даних	54
2.1.1.	54
2.1.2.	54
2.1.3.	54
2.2.	Метод зниження кількості хибно-позитивних прогнозів нейронної мережі за рахунок використання результатів семантично-близьких задач	54
2.2.1.	Використання близьких задач до задачі класифікації	54
2.2.2.	Використання близьких задач до задачі семантичної сегментації	54
2.3.	Метод сегментації важливих для класифікації ознак зображення в умовах відсутності розмітки для сегментації в навчальному наборі даних	54
2.3.1.	Комбінування задачі класифікації та сегментації	54
2.3.2.	Напівавтоматичне навчання ШНМ в задачі сегментації	54

2.3.3.	Пост-обробка результатів сегментації	54
2.3.4.	Висновки до другого розділу	55
Розділ 3. Експериментальні дослідження в різних задачах скринінгу		56
3.1.	Класифікація стадії осередків діабетичної ретинопатії	56
3.1.1.	Опис наборів даних	56
3.1.2.	Детальний опис структури нейронної мережі	57
3.1.3.	Детальний опис процедури навчання	57
3.2.	Класифікація раку шкіри та сегментація родимок	59
3.2.1.	Опис набору даних SIIM-ISIC Melanoma Classification	59
3.2.2.	Детальний опис структури нейронної мережі	60
3.2.3.	Детальний опис процедури навчання	61
3.2.4.	Результати експерименту	61
3.3.	Класифікація та сегментація формацій хмар	61
3.3.1.	Опис набору даних Understanding Clouds from Satellite Images	61
3.3.2.	Детальний опис структури нейронної мережі	62
3.3.3.	Результати експерименту	62
Розділ 4. Інструментальні засоби		63
4.1.	Узагальнена структура системи автоматизованого скринінгу	63
4.2.	Узагальнена структура системи навчання глибоких нейрон- них мереж	63
4.3.	Узагальнена структура прогнозування за допомогою глибо- ких нейронних мереж	63
4.4.	Апробація результатів дисертаційного дослідження	63
Висновки		64

ВСТУП

Обґрунтування вибору теми дослідження. В наш час активно розвиваються засоби превентивного управління в різних сферах людського життя. Сучасна медицина та виробництво активно розвиваються та стають все складнішими. Сучасна кліматологія здатна прогнозувати повені та урагани. Раннє діагностування захворювань, завчасне виявлення дефектів у виробках, та своєчасне прогнозування руху хмар дозволяє зменшувати витрати, зберігати природні ресурси та вчасно реагувати на зміни в довкіллі.

Задача автоматизованого скринінгу полягає в виявленні прихованих проблем на ранньому етапі без участі людини, поки ціна реагування на них є низькою. Серед небажаних ефектів скринінгу - можливість помилкової діагностики, створення неправдивого почуття впевненості у відсутності проблеми. З цих причин скринінгові дослідження повинні мати достатню чутливість і допустимий рівень специфічності.

Програмно-апаратні засоби відіграють одну з основних ролей в задачі автоматизованого скринінгу. Так, за допомогою фотокамер неперервно досліджуються сталеві листи для пошуку дефектів. Використання комп'ютеризованих офтальмоскопів дозволяє збільшити обсяги тестування захворювань ока в країнах, що розвиваються. Спеціальні супутники передають зображення земної поверхні в реальному часі, що допомагає вченим прогнозувати погоду.

Класифікація та семантична сегментація зображень є важливою складовою систем автоматизованого скринінгу і дозволяє виділяти об'єкти певного типу. Так, класифікація може показати наявність проблеми, а семантична сегментація - на її локалізацію, що спрощує подальшу роботу людини.

Особливою популярністю в задачах обробки зображень користуються штучні нейронні мережі (ШНМ), які на вході отримують зображення, а на виході можуть давати як мітку класу, так і карту сегментації. Однією з основних проблем при роботі з ШНМ є необхідність великої кількості добре розмічених даних для навчання.

На жаль, в задачах скринінгу часто немає можливості отримати достатньої кількості розмічених зображень, які б мали всю необхідну розмітку для виконання задачі, однак існують набори даних з розміткою для схожих задач. Можливість використання таких наборів даних для виконання близьких задач дозволяє значно розширити області використання ШНМ.

Підвищення точності класифікації та сегментації планарних зображень в системах автоматизованого скринінгу є актуальною науковою задачею.

Зв'язок роботи з науковими програмами, планами, темами, грантами. Вказується, в рамках яких програм, тематичних планів, наукових тематик і грантів, зокрема галузевих, державних та/або міжнародних, виконувалося дисертаційне дослідження, із зазначенням номерів державної реєстрації науково-дослідних робіт і найменуванням організації, де виконувалася робота.

Мета і завдання дослідження. Метою дослідження є підвищення достовірності класифікації та семантичної сегментації планарних зображень через розробку, удосконалення та розвиток методів обробки планарних зображень на основі штучних нейронних мереж.

Для досягнення поставленої мети в роботі вирішено наступні задачі:

- Проведено аналіз існуючих методів, алгоритмів та засобів обробки планарних зображень в системах автоматизованого скринінгу
- Розроблено метод багатозадачного навчання штучних нейронних мереж для роботи в умовах частково помилкової розмітки навчального набору

- Розроблено метод сегментації важливих для класифікації ознак зображення в умовах відсутності розмітки семантичної сегментації в навчальному наборі даних
- Удосконалено архітектуру штучної нейронної мережі для багатозадачного навчання
- Розвинуто нейромережевий метод обробки планарних зображень, який за рахунок навчання на декількох задачах одночасно підвищить точність класифікації та семантичної сегментації планарних зображень.
- Спроектовано та розроблено інструментальні засоби, що виконують розроблений метод
- Проведено випробування розробленого методу та інструментальних засобів в рамках експерименту

Об’єкт дослідження. Процес програмної обробки планарних зображень

Предмет дослідження. Методи семантичної сегментації та класифікації планарних зображень, структури та моделі згорткових нейронних мереж.

Методи дослідження. Для проведення досліджень застосовуються методи комп’ютерного зору для попередньої обробки зображень, методи математичної оптимізації для навчання штучних мереж.

Змістовно відзначається, що саме досліджувалось кожним методом; обґрунтовується вибір методів, що забезпечують достовірність отриманих результатів та висновків.

Наукова новизна отриманих результатів. *вперше:*

- Розроблено метод багатозадачного навчання штучних нейронних мереж для роботи в умовах частково помилкової розмітки навчального набору даних в задачах автоматизованого скринінгу

- Розроблено метод зниження дисперсії прогнозів нейронної мережі за рахунок використання результатів семантично-близьких задач при багатозадачному навчанні
- Розроблено метод сегментації важливих для класифікації ознак зображення в умовах відсутності розмітки для сегментації в навчальному наборі даних

удосконалено:

- Архітектуру штучної нейронної мережі для багатозадачного навчання

отримав подальший розвиток:

- Нейромережевий метод обробки планарних зображень, який за рахунок навчання на декількох задачах одночасно підвищує точність класифікації та семантичної сегментації планарних зображень.

Практичне значення отриманих результатів. Надаються відомості про використання результатів досліджень або рекомендації щодо їх практичного використання.

Особистий внесок здобувача. Якщо у дисертації використано ідеї або розробки, що належать співавторам, разом з якими здобувачем опубліковано наукові праці, обов'язково зазначається конкретний особистий внесок здобувача в такі праці або розробки; здобувач має також додати посилання на дисертації співавторів, у яких було використано результати спільних робіт.

Апробація матеріалів дисертації. Основні результати дослідження доповідалися на наукових конференціях різного рівня та наукових семінарах. Це такі конференції:

Структура та обсяг дисертації. Дисертація складається зі вступу, чотирьох розділів, висновків, списку використаних джерел і додатків. Робота містить X сторінок основного тексту, Y рисунків та Z таблиць. За-

гальний обсяг дисертації – N сторінок, список літературних джерел налічує K найменувань. Дисертація містить I додатків, розміщених на J сторінках.

РОЗДІЛ 1

АНАЛІЗ МЕТОДІВ, АЛГОРИТМІВ І ПРОГРАМНИХ ЗАСОБІВ ОБРОБКИ ПЛАНАРНИХ ЗОБРАЖЕНЬ

1.1. Аналіз задачі автоматизованого скринінгу

1.1.1. Задачі автоматизованого скринінгу в медицині. Серед багатьох застосувань скринінгу в медицині, особливо нагальною є потреба в методах скринінгу для агресивних прихованих хвороб в регіонах, де в більшості населення немає доступу до професійного лікаря. Так, агресивними хворобами, для яких утруднене діагностування на ранніх стадіях є діабетична ретинопатія та рак шкіри.

1.1.1.1. Скринінг раку шкіри. Рак шкіри є найбільш розповсюдженим видом злоякісних пухлин, і саме меланома є причиною більшості смертей від раку. Світова проблема захворюваності на меланому стрімко зростала за останні 50 років і стала проблемою, з якою намагаються боротися багато вчених з різних країн.

Меланома є п'ятим за поширеністю раком серед чоловіків та шостим за поширеністю раком серед жінок [1]. Подібно до інших типів раку, ранні та легкі стадії візуально навряд чи можна розрізнити. В наш час, дерматологи оцінюють кожну родинку пацієнта, щоб виявити незвичні осередки або такі, що, швидше за все, є злоякісними. Якщо меланому помітити вчасно, її можна вилікувати незначними оперативними втручаннями.

Огляд літератури Недавні дослідження в галузі автоматичного виявлення злоякісних утворень пов'язані з найсучаснішими підходами до глибокого навчання в розпізнаванні зображень. Набагато менше робіт використовують класичне машинне навчання та сконструйовані дослідниками

ознаки.

Тут наведено найвпливовіші роботи в цій галузі. Так, Mustafa et al. [7] створив підхід з підібраними вручну ознаками (GrabCut для сегментації раку) та методом опорних векторів для класифікації ракових уражень. Також, Nasiri et al. [8] згенерував похідні зображення за допомогою декількох алгоритмів і використав на них метод k-найближчих моделей сусідів для вирішення завдання.

Брінкер та ін. [9] проводив експерименти із попередньо навченими на наборі даних ImageNet згортковими нейронними мережами, такими як ResNet-50, для класифікації ранніх стадій меланоми. Автори використали 4204 перевірених біопсією зображення меланоми та звичайних родинок. Крім того, були інтегровані новітні на той момент методи глибокого навчання: різні темпи навчання для різних частин нейронної мережі, зменшення темпу навчання на основі функції косинуса, стохастичний градієнтний спуск з перезапуском для того щоб уникнути локальних мінімумів.

Коделла та ін. [10] запропонували систему сегментації та класифікації меланоми за дермоскопічними зображеннями шкіри. Для класифікації хвороб вони застосували ансамбль останніх методів машинного навчання, включаючи глибокі залишкові мережі, згорткові нейронні мережі тощо. Вони довели, що ансамблі здатні давати кращі результати, ніж моделі окремо.

Насірі та ін. [4] запропонували класифікацію уражень шкіри за допомогою глибокого навчання для раннього виявлення меланоми в системі міркувань на основі прецедентів (англ. case-based reasoning). Цей підхід був використаний для отримання схожих вхідних зображень із бази даних прецедентів запропонованої системи DePicT Melanoma Deep-CLASS для підвищення точності рекомендацій щодо запитуваної проблеми (наприклад, зображення родинки). Їх метод, що заснований на глибоких згорткових нейронних мережах, генерує ознаки з зображень, щоб використовувати їх у процесі пошуку в базі даних. Інтеграція цього підходу до DePicT Melanoma

CLASS значно покращила ефективність класифікації зображень та якість рекомендаційної частини системи.

Дослідження в галузі багатозадачного навчання також проводили Сонг та ін. [5]. Вони запропонували нейронну мережу, яка може одночасно виконувати завдання детекції, класифікації та сегментації уражень шкіри, не вимагаючи додаткових етапів попередньої обробки або подальшої обробки. Подібну роботу представили Чен та співавт. [6], вони використали багатозадачну мережу U-Net для задачі детекції та сегментації. Янг та ін. [11] запропонував більш складну багатозадачну модель, яка одночасно вирішує завдання сегментації уражень та дві незалежні задачі бінарної класифікації, використовуючи спільності та відмінності між завданнями.

1.1.1.2. Скринінг діабетичної ретинопатії. Діабетична ретинопатія є одним із найбільш загрозливих ускладнень діабету, при якому пошкодження сітківки викликає сліпоту. Вона пошкоджує кровоносні судини тканини сітківки, викликаючи витік рідини та погіршення зору. Поряд із захворюваннями, що призводять до сліпоти, такими як катаракта і глаукома, ретинопатія є одним із найпоширеніших захворювань, згідно зі статистикою США, Великобританії та Сінгапуру.

Лікарі встановили чотири стадії діабетичної ретинопатії:

- Легка неproліферативна ретинопатія, найраніша стадія, коли можуть виникати лише мікроаневризми;
- Помірна неproліферативна ретинопатія, стадію якої можна описати втратою здатності кровоносних судин до транспортування крові через набряк з прогресуванням захворювання;
- Важка неproліферативна ретинопатія призводить до обмеженого кровопостачання сітківки через підвищений набряк великої кількості кровоносних судин;
- Проліферативна діабетична ретинопатія - це запущена стадія, коли

фактори росту, що виділяються сітківкою, активізують проліферацію нових кровоносних судин, зростаючи вздовж оболонки сітківки в склоподібному тілі, заповнюючи око.

Щонайменше 56% нових випадків можна уникнути за допомогою належного та своєчасного лікування та скринінгу очей. Однак, початкова стадія цього захворювання не має помітних для пацієнта ознак, і виявити його на ранній стадії є справжньою проблемою. Більш того, добре навчені діагности іноді не можуть вручну оцінити стадію за діагностичними зображеннями очного дна пацієнта.

Огляд літератури

Багато дослідницьких зусиль було присвячено проблемі раннього виявлення діабетичної ретинопатії. Перш за все, дослідники намагалися використовувати класичні методи комп'ютерного зору та машинного навчання, щоб забезпечити відповідне рішення цієї проблеми.

Наприклад, Priya et al. запропонували підхід на основі комп'ютерного зору для виявлення діабетичної ретинопатії за допомогою кольорових зображень очного дна. Автори створили набір ознак із вихідного зображення, використовуючи класичні методи обробки зображень, і використали метод опорних векторів для бінарної класифікації. Їх метод досяг чутливості 98%, специфічності 96% та точності 97% на тестовому наборі з 250 зображень.

Крім того, інші дослідники намагалися використати інші моделі для багатокласової класифікації, наприклад, застосовуючи аналіз головних компонент до зображень та використовуючи дерева рішень, Баєсові класифікатори або метод найближчих сусідів *condc* з найкращими результатами 73.4% точності та 68.4% для F-міри, використовуючи набір даних із 151 зображення з різною роздільною здатністю.

Зі зростанням популярності підходів, заснованих на глибокому навчанні, з'явилися методи, які застосовують глибокі згорткові нейронні мережі

до цієї проблеми. Пратт та ін. pratt розробили архітектуру нейронної мережі та використали аугментацію даних, яка може ідентифікувати складні ознаки захворювання, пов'язані із задачею класифікації, такі як мікроаневризми, ексудат та крововиливи в сітківку ока, і, отже, автоматично діагностувати стадію захворювання. Цей метод досяг чутливості 95% і точності 75% на 5000 валідаційних зображень. Крім того, є й інші роботи про використання глибоких штучних нейронних мереж від інших дослідників lam, li.

Asiri та ін. провели аналіз значної кількості доступних методів та наборів даних, висвітливши їх плюси та мінуси asiri. Крім того, автори вказали на проблеми, які слід вирішити при розробці та вивченні ефективних та надійних алгоритмів глибокого навчання для різних проблем діагностики діабетичної ретинопатії, та звернули увагу на напрямки подальших досліджень.

Інші дослідники також намагалися здійснити трансферне навчання за допомогою згорткових нейронних мереж. Хагош та ін. hagos спробував навчити InceptionNet V3 для класифікації 5 класів з нейронною мережею, натренованою на наборі даних ImageNet і досяг точності 90,9% Сарки та ін. sarki провів дослідження з навчання різних архітектур, зокрема ResNet50, Xception, DenseNets та VGG за допомогою попереднього навчання на наборі даних ImageNet і досяг найкращої точності 81.3%. Обидві групи дослідників використовували набори даних, які надавали APTOS та Kaggle.

1.1.2. Задача автоматизованого скринінгу на виробництві.

1.1.3. Задачі автоматизованого скринінгу в метеорології. Однією з найцінніших особливостей визначення кліматичної моделі Землі є поведінка хмар. Однак дослідження їх поведінки є однією з найскладніших частин, оскільки вимагає досконалого розуміння всіх процесів в атмосфері.

Класифікація різних типів організації хмар допомагає покращити розуміння цих хмар, що, в свою чергу, допоможе нам побудувати кращі кліматичні моделі.

Дослідники з Інституту метеорології імені Макса Планка зібрали найбільший набір даних, що складається з приблизно 10 000 фотографій хмар в видимому спектрі з супутників Terra і Aqua MODIS. Завдяки краудсорсинговій спільноті Zooniverse, вони створили анотований набір даних, в якому хмари позначені чотирма типами масок: цукор, квітка, гравій, риба (англ. Sugar, Flower, Gravel, Fish). Однак, через недосконалу процедуру маркування фотографій, та через те, що маркування було зроблене непрофесіоналами, розмітка є частково помилковою. Так, маски сегментації класів містять багато пікселів, що належать до фону, та деякі хмари не мають масок сегментації.

Огляд літератури Щоб описати широкий спектр дослідницьких робіт, розглянуто роботи, що використовують як супутникові зображення в видимому спектрі, так і в інших діапазонах: мультиспектральні та інфрачервоні.

Один із методів виявлення хмар був розроблений Чжу та співавт. [2], вони запропонували метод під назвою Fmask (функція маски) для виявлення хмар та їхніх тіней на зображеннях із супутника Landsat 7. Fmask використовує підходи, засновані на правилах на основі фізичних властивостей хмар, щоб відокремити потенційні хмарні регіони від чистого неба. В якості вхідних даних метод використовує інформацію із семидіапазонних датчиків Enhanced Thematic Mapper (ETM) та Enhanced Thematic Mapper Plus (ETM+), якими обладнаний супутник Landsat. Альтернативний підхід був запропонований Harb et al. [3], автори проаналізували мультиспектральні дані середньої роздільної здатності з супутників програми CBERS. Даний алгоритм використовує набір математичних операцій над спектральними смугами, щоб покращити видимість хмар та їхніх тіней.

Ці методи дають точні результати, але в значній мірі залежать від мо-

делей датчиків (оскільки вони є методами, заснованими на правилах), а пропоновані рішення не є масштабованими до інших типів датчиків.

Hu et al. [4] представили більш загальне рішення, використовуючи методи комп'ютерного зору для виявлення декількох низькорівневих ознак, таких як колір, особливості текстури тощо. Для оцінки піксельних масок автори використали класичні алгоритми машинного навчання. Озкан та ін. застосували глибокі нейронні мережі (такі як Feature Pyramid Network) для сегментації хмар із низькоорбітальних RGB-зображень супутників Gokturk-2 та RASAT.

1.2. Аналіз методів та алгоритмів обробки зображень

1.2.1. Особливості планарних зображень. Глибина сцени незначна відносно відстані до камери. Масштаб об'єктів в сцені є постійним.

1.2.2. Feature detection.

1.2.3. Задача класифікації зображень та відомі методи її розв'язання.

1.2.4. Задача семантичної сегментації зображень та відомі методи її розв'язання. Before 2000, we used several methods in digital image processing: threshold segmentation, region segmentation, edge segmentation, texture features, clustering and so on. From 2000 to 2010, there are four main methods: graph theory, clustering, classification and combination of clustering and classification.

1.3. Методи глибинного машинного навчання

Глибинне машинне навчання - це частина більш широкого сімейства методів машинного навчання, заснованих на штучних нейронних мережах.

(ШНМ). Алгоритми глибинного машинного навчання моделюють високо-рівневі абстракції за допомогою глибинного графу з декількох шарів, що побудовані з лінійних, чи нелінійних перетворень.

1.3.1. Загальні відомості про штучні нейронні мережі. Штучні нейронні мережі — це обчислювальні системи, натхнені біологічними нейронними мережами. ШНМ ґрунтується на сукупності з'єднаних вузлів, що називають штучними нейронами (аналогічно до біологічних нейронів у головному мозку тварин). Кожне з'єднання (аналогічне синапсу) між штучними нейронами може передавати сигнал від одного до іншого. Штучний нейрон, що отримує сигнал, може обробляти його, й потім сигналізувати іншим нейронам, приєднаним до нього [?].

1.3.2. Згорткові нейронні мережі. Революція в розпізнавання образів була зроблена за допомогою згорткових нейронних мереж (ЗНМ). Раніше, для задач розпізнавання використовувалися фільтри, які обиралися вручну, а після них використовувався простий класифікатор. Велика перевага нейронних мереж, полягає в тому, що потрібні лише тренувальні дані. На основі даних, фільтри і класифікатори навчаються автоматично. Це стало особливо потужним методом в завданнях розпізнавання зображень.

Дані з зображень захоплюється за допомогою операції згортки. Використовуючи згорткові ядра для сканування цілого зображення, потрібно вивчити порівняно небагато параметрів відносно повнозв'язних штучних нейронних мереж. Окрім безпосередньо операції згортки, сучасні ЗНМ використовують нелінійні функції активації, операції підвибірки та нормалізації.

Згорткові шари. Згорткові шари в глибоких нейронних мережах є основним блоком, що дозволяє формувати карти ознак.

Активациі. Функції активації забезпечують нелінійність нейронної мережі, виконуючи нелінійне перетворення карти ознак, отриманої від згорткового, або повнозв'язного шару.

Найбільш популярними функціями активації в даний час є [?]:

- Сигмоподібна (Sigmoid) [?]
- Гіперболічний тангенс (TanH) [?]
- Лінійний ректифікатор (ReLU) [?]
- Нещільний лінійний ректифікатор (LeakyReLU) [?]
- SoftPlus [?]
- Доповнена тотожна функція (Bent identity) [?]
- Swish [?]
- Mish [?]

Графіки зазначених функцій зображено на рис. 1.1.




Рис. 1.1. Графіки популярних функцій активації [?]

Підвибірки. Шари підвибірки використовуються для зменшення просторової роздільної здатності та агрегації просторових ознак. В сучасних нейронних мережах використовуються шари підвибірки з функцією максимуму та середнього арифметичного. Також існують шари підвибірки з

іншими функціями, але вони не набули загального застосування.

Нормалізації. В сучасних нейронних мережах, шари нормалізації використовуються для стабілізації процесу навчання. Розподіл входів кожного шару змінюється під час навчання, оскільки змінюються параметри попередніх шарів. Це уповільнює навчання, вимагаючи нижчих темпів навчання та ретельної ініціалізації параметрів.

Нормалізація проводиться над картами ознак, або їх частинами, приводячи їх до розподілу з середнім значенням 0 та стандартним відхиленням 1. Різні типи нормалізацій які застосовуються в нейронних мережах включають:

- Пакетна нормалізація (batch normalization)[?]
- Пошарова нормалізація (layer normalization)[?]
- Поекземплярна нормалізація (instance normalization) [?]
- Групова нормалізація (group normalization) [?]

Візуалізація різних типів нормалізації зображена на рис. 1.2. Тут N - кількість карт ознак в пакеті, C - розмірність каналів карти ознак, H , W - просторова розмірність одного каналу. Синім виділено набори ознак, на яких обчислюється середнє значення та стандартне відхилення.




Рис. 1.2. Візуалізація різних типів нормалізації [?]

1.3.3. Визначні сучасні архітектури ШНМ класифікації зображень.

Нейронна мережа AlexNet. AlexNet є однією з найперших вдалих спроб застосування штучних згорткових нейронних мереж до зображень у великому масштабі. На відміну від більш ранніх робіт, автори досягли великого прориву на великому наборі даних ImageNet [?].

Архітектура нейронної мережі є логічним продовженням розробок Я. Лекуна [?] для розпізнавання рукописних літер за допомогою згорткових нейронних мереж. AlexNet складається з восьми шарів, перші п'ять з яких - згорткові, а останні три - повнозв'язними шарами. AlexNet використовує функцію активації ReLU, яка демонструвала покращені результати навчання в порівнянні з сигмоподібною. Для збільшення поля зору, автори використали великий розмір ядра в перших згорткових шарах (11 та 5 пікселів відповідно)

Для того, щоб мати можливість навчання не великій кількості зображень порівняно високої роздільної здатності, автори розробили алгоритм паралельного навчання на декількох графічних процесорах (GPU).




Рис. 1.3. Граф нейронної мережі AlexNet [?]

Також, автори вперше показали можливість використання карт ознак як міри подібності для входних зображень та необхідність регуляризації для запобігання перенавчанню.

AlexNet вважається однією з найвпливовіших статей, опублікованих в галузі комп'ютерного зору, завдяки чому було опубліковано багато інших

публікацій із використанням CNN та GPU для прискорення глибокого навчання.

Нейронна мережа VGGNet. VGGNet є інкрементальним покращенням архітектури AlexNet, в якому адресовано проблему продуктивності та систематизовано залежність точності від глибини нейронної мережі. Покращення продуктивності в порівнянні з AlexNet досягається заміною великих розмірів ядра згортки (11 і 5 у першому та другому згортковому шарі, відповідно) кількома згортками з розміром ядра 3x3 одна за одною. Також, за рахунок використання більшої кількості нелінійних активацій, підвищується дискримінаційна здатність нейронної мережі. Так, три згортки з ядром 3x3 одна за одною та кроком 1 мають той самий розмір поля зору що й одна згортка з розміром ядра 7x7, але кількість задіяних параметрів становить $3 \cdot (3^2 C^2)$ порівняно з $7^2 C^2$ параметрів для ядер розміром 7x7. Тут C - це кількість вхідних та вихідних каналів згорткового шару.

Автори порівнюють декілька нейронних мереж, які відрізняються лише кількістю шарів. Вихідна таблиця порівняння архітектур зазначена на рис. 1.4.

В даній роботі було продемонстровано, що глибина нейронної мережі вигідна для точності класифікації, а також того, що можна досягти високої точності за допомогою звичайної архітектури згорткової нейронної мережі.

Сімейство архітектур нейронних мереж Inception. Мережа Inception [?] стала важливою віхою в розвитку згорткових нейронних мереж. До цієї роботи, згорткові нейронні мережі являли собою послідовні операції згортки, активації та підвибірки. До сімейства Inception входять нейронні мережі, що були спеціально розроблені для підвищення точності та продуктивності.

Автори розглядають проблему варіативності розміру об'єктів на зображеннях: вибір правильного розміру ядра для операції згортки стає важким.

ConvNet Configuration					
A	A-LRN	B	C	D	E
11 weight layers	11 weight layers	13 weight layers	16 weight layers	16 weight layers	19 weight layers
input (224×224 RGB image)					
conv3-64	conv3-64 LRN	conv3-64 conv3-64	conv3-64 conv3-64	conv3-64 conv3-64	conv3-64 conv3-64
maxpool					
conv3-128	conv3-128	conv3-128 conv3-128	conv3-128 conv3-128	conv3-128 conv3-128	conv3-128 conv3-128
maxpool					
conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256 conv1-256	conv3-256 conv3-256 conv3-256	conv3-256 conv3-256 conv3-256 conv3-256
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 conv1-512	conv3-512 conv3-512 conv3-512	conv3-512 conv3-512 conv3-512 conv3-512
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 conv1-512	conv3-512 conv3-512 conv3-512	conv3-512 conv3-512 conv3-512 conv3-512
maxpool					
FC-4096					
FC-4096					
FC-1000					
soft-max					

Рис. 1.4. Порівняння архітектур VGGNet різної глибини [?]

Більше ядро краще підходить для виділення інформації, яка розповсюджена більш глобально, а менше ядро - для інформації, яка розповсюджується локально.

Для вирішення цієї проблеми, автори використовують декілька операцій згортки з різними розмірами ядра в одному шарі нейронної мережі. Оскільки виконання згорток з великою кількістю каналів є довгою операцією, автори зменшують кількість каналів за допомогою згорток з розміром ядра 1×1 . Один такий шар називається *блоком Inception*, архітектура якого зображена на рис. 1.5

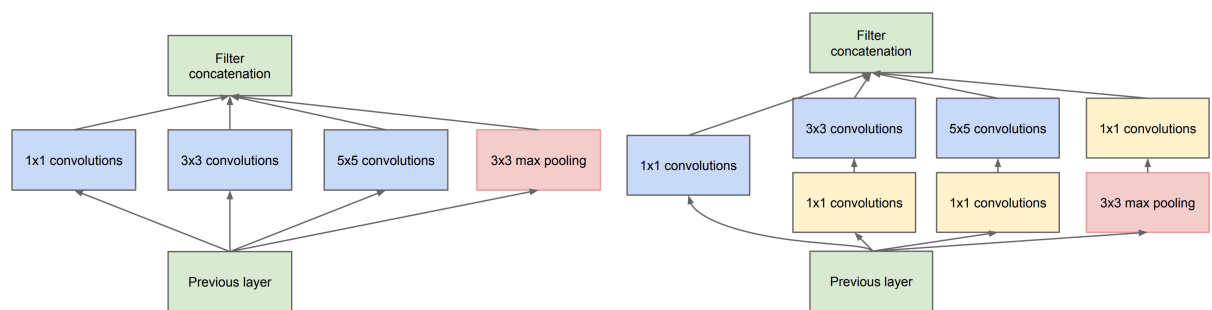


Рис. 1.5. Блок-схема Inception v1 до та після розкладу[?]

Нейронна мережа GoogLeNet [?] складалася з 22 шарів в глибину та була найглибшою на той час. Для того, щоб запобігти затуханню градієнтів, використовувалися додаткові класифікатори на менш глибоких рівнях, результати яких було додано до функції втрат.

В наступних роботах [?], автори продовжують ідею зменшення кількості операцій, для чого вводять розкладання згорток з великим розміром ядра на декілька менших згорток. Так, автори пропонують розкладання згортки з ядром розміру 5×5 на дві згортки з розміром ядра 3×3 , а згортки з розміром ядра 3×3 на дві згортки розміру 1×3 та 3×1 відповідно. Це дозволяє зменшити кількість параметрів в нейронній мережі при збереженні глибини, зменшуючи необхідні ресурси для обчислення.

Схема блоків Inception v2 та v3 зображено на рис. 1.6

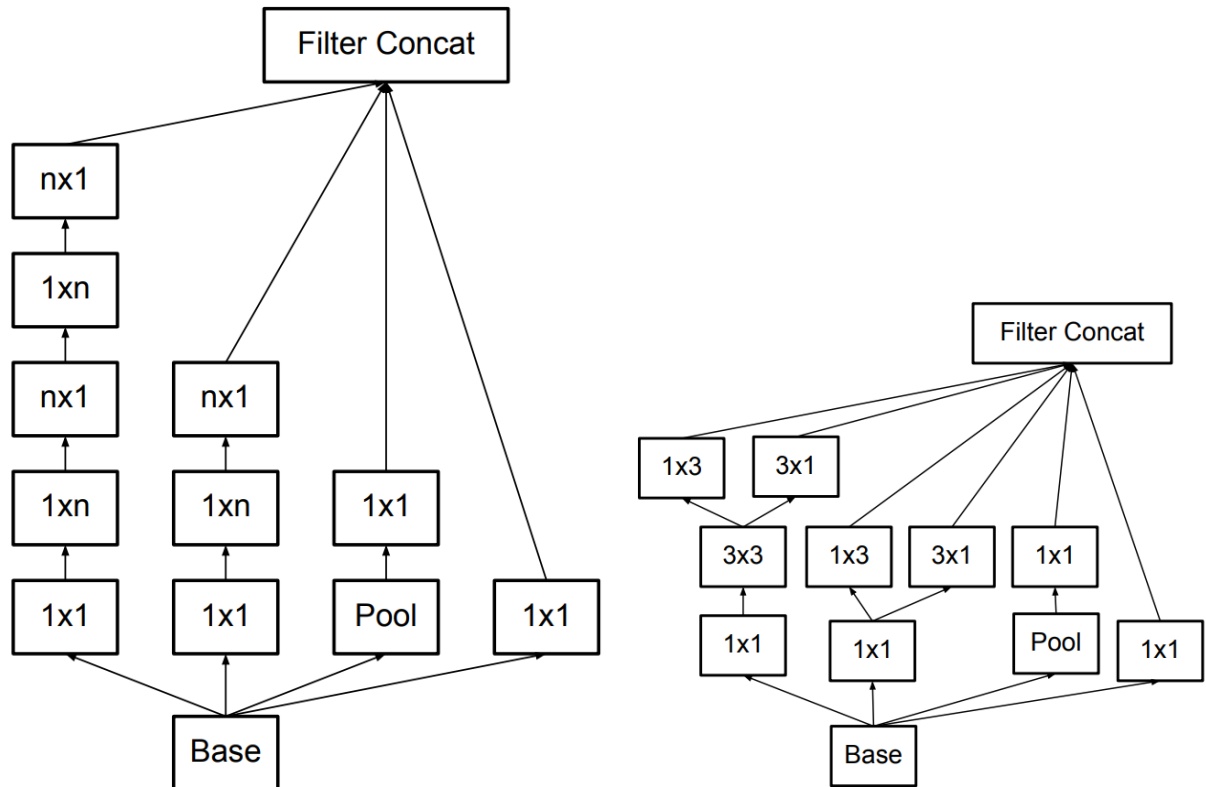


Рис. 1.6. Блок-схема Inception v2 до та після розкладу[?]

В нейронній мережі Inception v2 вперше було застосовано метод пакетної нормалізації [?], що дозволило значно пришвидшити навчання. Також, було показано, що додаткові класифікатори не мають впливу на згасання градієнтів, але мають властивості регуляризації, особливо на останніх стадіях навчання.

Сімейство архітектур нейронних мереж ResNet. Сімейство нейронних мереж ResNet було засновано на новому методі залишкового навчання, що був представлений в тій самій роботі, що й архітектура нейронної мережі [?]. Автори розв'язують проблему того, що збільшення глибини нейронної мережі зменшує точність як на навчальному, так і на тестувальному наборі даних.

В роботі показано, що метод стохастичного градієнтного спуску не придатний до оптимізації глибоких нейронних мереж. Так, наведено експери-

мент, в якому між шарами неглибокої нейронної мережі використано шари тотожного відображення або додаткові згорткові шари з функцією активації. Показано, що для більш глибокої нейронної мережі має існувати рішення з точністю не меншою, ніж для неглибокої нейронної мережі, але, на практиці, точність більш глибокої нейронної мережі залишається нижчою. Для збільшення глибини нейронних мереж без втрати точності, в роботі запропоновано метод залишкового навчання.

Нехай $\mathcal{H}_l(x_{l-1})$ - це відображення, що задається декількома шарами нейронної мережі, де x_{l-1} - це вхідний тензор до першого з цих шарів. Якщо припустити, що декілька нелінійних шарів можуть апроксимувати будь-яку нелінійну функцію, то логічно припустити, що вони можуть апроксимувати і залишкову функцію: $\mathcal{F}_l(x_{l-1}) = \mathcal{H}_l(x_{l-1}) - x_{l-1}$. Тоді, оригінальне відображення стає $\mathcal{H}_l(x_{l-1}) = \mathcal{F}_l(x_{l-1}) + x_{l-1}$. Хоча ці відображення є еквівалентними, алгоритму оптимізації «простіше» таким чином вивчити тотожну функцію, оскільки для цього достатньо наблизити ваги шарів нейронної мережі до нуля.

В роботі автори пропонують блоки нейронних мереж, що складаються з декількох згорткових шарів з функцією активації ReLU та об'єднання з вхідним тензором першого шару. Схема таких блоків зображена на рис. 1.7




Рис. 1.7. Схема залишкових блоків нейронних мереж ResNet18 та ResNet50 [?]

Завдяки використанню таких блоків, стала можливою побудова надзвичайно глибоких нейронних мереж. В експериментах, автори запропонували

архітектури, що складаються з 18, 34, 50, 101, 152 та 1202 згорткових шарів, та можуть бути оптимізовані стандартними методами (наприклад, методом стохастичного градієнтного спуску).

Сімейство архітектур нейронних мереж DenseNet. Архітектура нейронних мереж сімейства DenseNet [?] є логічним продовженням ідей, запропонованих в архітектурі ResNet. В даній архітектурі також використовується метод залишкового навчання, але, на відміну від архітектури ResNet, послідовні шари поєднані кожний з кожним.

Для того, щоб підвищити об'єм інформації, яким обмінюються шари нейронної мережі, автори пропонують ввести пряме з'єднання від кожного шару до всіх наступних:

$$x_l = \mathcal{H}([x_0, x_1, x_3 \dots x_{l-1}]) \quad (1.1)$$

де $[x_0, x_1, x_3 \dots x_{l-1}]$ - конкатенація всіх карт активації з шарів від 0 до $l - 1$.

Така зміна архітектури дозволила останнім шарам перевикористовувати ознаки з попередніх, що, в свою чергу, дозволило зменшити кількість параметрів в нейронній мережі та підвищити точність.

Граф нейронної мережі DenseNet зображено на рис. 1.8.




Рис. 1.8. Архітектура нейронної мережі DenseNet [?]

На практиці, хоча архітектура дозволяє досягти більшої точності з використанням меншої кількості параметрів, на час виходу роботи, більшість реалізацій, заснованих на популярних фреймворках машинного навчання вимагали більшої кількості оперативної пам'яті через необхідність копіювання карт активацій для кожного з шарів. Таким чином, наївна реалізація

архітектури DenseNet потребувала $\mathcal{O}(\frac{L(L-1)}{2})$ оперативної пам'яті. З розвитком фреймворків машинного навчання, була реалізована можливість перевикористання тензорів без копіювання, що дозволило знизити потребу оперативної пам'яті до $\mathcal{O}(L)$ [?].

Сімейство архітектур нейронних мереж ResNeXt. Архітектури сімейства ResNeXt [?] є логічним продовженням методів, застосованих в архітектурах Inception та ResNet. Основною ідеєю цієї архітектури є використання набору з декількох простих однакових трансформацій в просторі низької розмірності в кожному з шарів нейронної мережі.

Так, автори пропонують розділити згортковий шар на декілька паралельних трансформацій, результати з яких агрегуються:

$$\mathcal{H}(x_{l-1}) = \sum_{i=1}^C \mathcal{T}_i(x_{l-1}) \quad (1.2)$$

де \mathcal{T}_i - це будь-яка нелінійна функція, що проектує вхід x_{l-1} до простору низької розмірності, трансформує його, та проектує результат назад в простір високої розмірності. Тут C - потужність множини трансформацій.

Графічну репрезентацію блоку ResNeXt зображено на рис. 1.9

В роботі автори проводять експерименти відносно важливості параметру C відносно інших, та показують, що збільшення C підвищує точність більше, ніж підвищення кількості каналів згорток. Також, в роботі показано, що такий метод здатний створювати кращі репрезентації вхідних даних.

Сімейство нейронних мереж EfficientNet. Сімейство нейронних мереж EfficientNet також є логічним продовженням архітектури ResNet. В даній роботі вперше розглядається узагальнений метод масштабування згорткових нейронних мереж для збільшення точності під заданий обчислювальний бюджет.

Автори пропонують метод, за допомогою якого можна масштабувати




Рис. 1.9. Графічна репрезентація блоку ResNeXt [?]

одночасно вхідну роздільну здатність зображення, глибину та ширину нейронної мережі. Нведено спостереження, що ці величини не є незалежними.

Інтуїтивно зрозуміло, що для зображень із більш високою роздільною здатністю необхідно збільшити глибину мережі, щоб більш збільшити поле зору та захопити більше пікселів у більшому зображенні. Відповідно, також необхідно збільшувати ширину мережі, коли роздільна здатність збільшується, для того, щоб мати можливість розпізнати більшу кількість ознак на зображеннях із високою роздільною здатністю.

Для цього, структура нейронної мережі формулюється як задача максимізації точності в залежності від ширини, глибини та роздільної здатності:

$$\max \text{Accuracy}(\mathcal{N}(d, w, r)) : \quad (1.3)$$

$$\mathcal{N}(d, w, r) = \bigodot_{i=1..s} \hat{\mathcal{F}}_i^{d \cdot \hat{L}_i}(X_{(r \cdot \hat{H}_i, r \cdot \hat{W}_i, w \cdot \hat{C}_i)}) \quad (1.4)$$

де w, d, r - параметри масштабування ширини, глибини та роздільної здатності відповідно,

та $\hat{\mathcal{F}}_i$ - функція, що задається архітектурою шару,

$\hat{L}_i, \hat{H}_i, \hat{W}_i$ - розміри карти активації, а \hat{C}_i - кількість каналів.

Також, пропонується визначення залежності між d, w, r :

$$d = \alpha^\phi \quad (1.5)$$

$$w = \beta^\phi \quad (1.6)$$

$$r = \gamma^\phi \quad (1.7)$$

так, що виконується наступне:

$$\alpha \cdot \beta^2 \cdot \gamma^2 \approx 2 \quad (1.8)$$

$$\alpha \geq 1, \beta \geq 1, \gamma \geq 1 \quad (1.9)$$

де ϕ - множник, що задається в залежності від наявного обчислювального бюджету.

Завдяки цьому методу масштабування, автори представляють 8 варіантів нейронної мережі, що відрізняється необхідною точністю та продуктивністю: від найменшої до найбільшої.

1.3.4. Визначні архітектури ШНМ для сегментації зображень.

Повністю згорткова нейронна мережа. (англ. *Fully-convolutional network, FCN*) [?] - це перша нейронна мережа, що використовувала лише шари згортки, активації та підвибірки, не використовуючи повнозв'язних шарів в задачі семантичної сегментації.

Основною перевагою цього підходу стала можливість навчання та прогнозування на зображеннях різного розміру, без зміни параметрів нейронної мережі.

В даній роботі вперше було застосовано індуктивний переніс знань з задачі класифікації на задачу сегментації. Для цього перші шари нейрон-

ної мережі було ініціалізовано за допомогою параметрів, отриманих після тренування на наборі даних ImageNet [?].

Для отримання масок сегментації, повнозв'язні шари було сконвертовано в згорткові, а також було додано інформацію з перших шарів для збереження просторових ознак. Граф нейронної мережі FCN зображено на рис. 1.10.

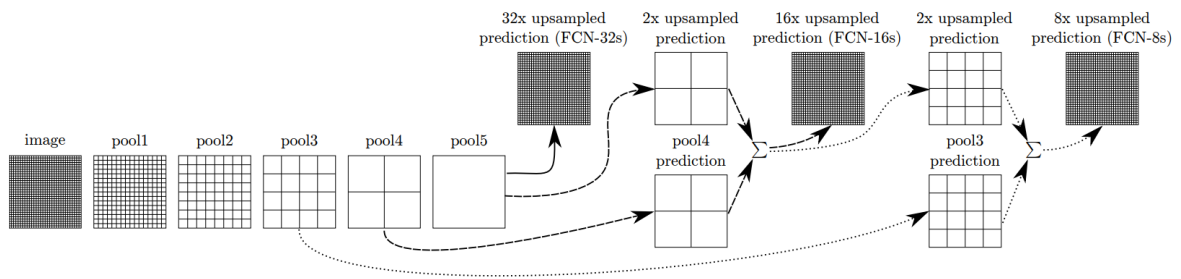


Рис. 1.10. Граф нейронної мережі FCN [?]

Тут, *pool[1-5]* - карти активації після відповідних операцій підвибірки, а *upsampled* - карти активації після білінійної інтерполяції.

Нейронна мережа SegNet. SegNet (*сегментаційна мережа*) [?]-перша повністю згорткова нейронна мережа, що використовувала архітектуру типу "енкодер-декодер" для вирішення задачі семантичної сегментації. В даній архітектурі, енкодер стискає семантичне представлення до більш компактного простору. Роль декодера полягає у відображенні з компактного простору з низькою роздільною здатністю у карту активації повного розміру для класифікації кожного пікселя.

Архітектура мережі енкодера топологічно ідентична 13 згортковим шарам мережі VGG16 [?].

Новина SegNet полягає в тому, як декодер підвищує розширення карт активації низького розширення. Так, декодер використовує індекси операцій підвибірки, обчислені на відповідному шарі енкодера, для нелінійного підвищення розширення. Карти активації підвищеного розширення вияв-

ляються розрідженими, для того, щоб зробити їх щільними, виконується декілька операцій згортки. Структура SegNet зображена на рисунку ??.




Рис. 1.11. Граф нейронної мережі SegNet [?]

Нейронна мережа PSPNet. Pyramid Scene Parsing Network (PSPNet) - це подальший розвиток ідеї FCN, в якому виправлено декілька значних проблем архітектури FCN. Серед основних проблем FCN автори відзначили:

- Відсутність можливості обробки інформації про контекст рівня зображення
- Різний розмір та вигляд різних об'єктів одного класу

Для того, щоб вирішити ці проблеми, автори запропонували додати до архітектури FCN модуль пірамідальної підвибірки (*англ. Pyramid Pooling Module*). Цей модуль складається з чотирьох операцій підвибірки з різними масштабом, що дозволяє захопити контекст зображення на різних рівнях.

Структура PSPNet та модуля підвибірки зображена на рисунку ??.

UNet. U-Net (*U-подібна мережа*) [?] - повністю згорткова нейронна мережа, що складається з симетричних енкодера та декодера, в яких, на відміну від SegNet замість індексів підвибірки, до декодера передаються карти активації енкодера напрямку, через операцію конкатенації. Окрім спрощення кодування, така організація мережі дозволила спростити навчання, оскільки передача інформації стала повністю диференційованою.

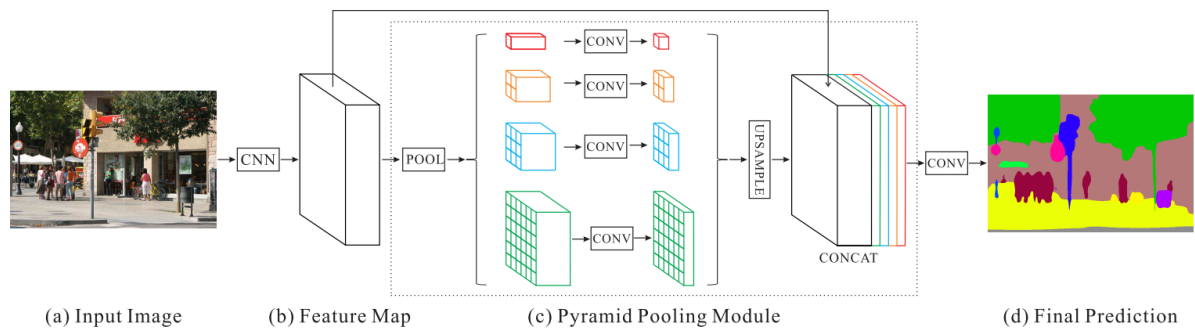


Рис. 1.12. Граф нейронної мережі PSPNet [?]

Також, для забезпечення можливості навчання на малій кількості даних, використовується велика кількість різноманітних аугментацій вхідних зображень, щоб синтетично збільшити розмір набору даних.

Для більш чіткого розподілення близько розташованих об'єктів, автори запропонували спеціальну зважену функцію втрат, що забезпечувала більш чітке формування границь об'єктів.

Хоча, оригінально ця архітектура була запропонована для семантичної сегментації планарних мікроскопічних знімків, подальші дослідження показали її застосовність в широкому спектрі задач семантичної сегментації.

Структура нейронної мережі U-Net зображена на рисунку 1.13.

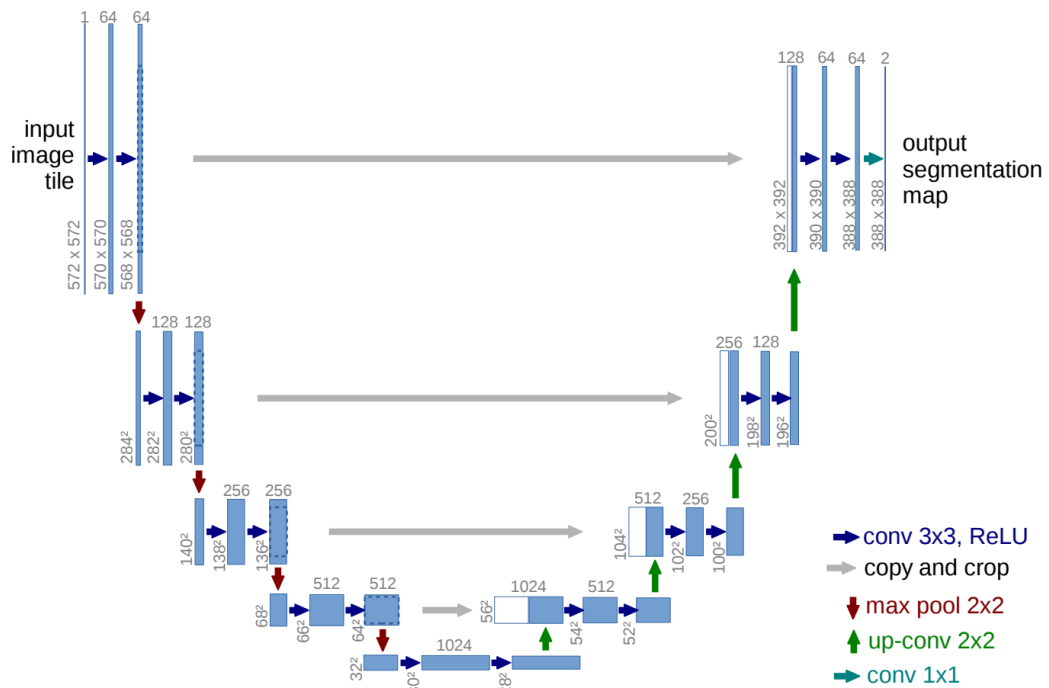


Рис. 1.13. Граф нейронної мережі U-Net [?]

LinkNet. Архітектура нейронної мережі LinkNet є подальшим розвитком архітектури U-Net, і також складається з енкодера та декодера, що поєднані через проміжні карти активації.

На відміну від U-Net, LinkNet використовує ResNet в якості енкодера, а також для поєднання карт активації енкодера та декодера використовує операцію суми, замість конкатенації. Це дозволило значно зменшити кількість параметрів, підвищити швидкість тренування при збереженні точності сегментації.

Також, автори LinkNet вперше використали індуктивний переніс з ImageNet виключно до енкодера, залишивши декодер випадково ініціалізованим на момент початку навчання.

Структура нейронної мережі LinkNet зображена на рисунку 1.14.

В подальших роботах, автори зазвичай називають свої архітектури U-Net-подібними, хоча, насправді, вони є ближчими до LinkNet. [?, ?, ?]




Рис. 1.14. Граф нейронної мережі LinkNet [?]

Feature Pyramid Network. Вперше розроблена для задач детекції об'єктів, Feature Pyramid Network (FPN) [?], була успішно застосована для задач семантичної сегментації [?].

Структура FPN складається з двох шляхів: на одному з них зменшується просторова та розмірність збільшується глибина карт ознак (шлях знизу вверху), на іншому - навпаки (шлях зверху-вниз). Шлях знизу-вверх представляє собою звичайну згорткову нейронну мережу (зазвичай, з сімейства ResNet). Шлях зверху-вниз представляє собою послідовність згорток та операцій підвищення розширення.

Для отримання карти активації, з якої буде отримано результат семантичної сегментації, всі рівні декодера оброблюються двома операціями згортки, після чого приводяться до однакового просторового розширення. З цієї карти ознак отримується фінальна карта сегментації за допомогою операції згортки.

Структура нейронної мережі FPN для семантичної сегментації зображена на рисунку 1.15.




Рис. 1.15. Граф нейронної мережі FPN [?]

Сімейство нейронних мереж DeepLab. Нейронні мережі з сімейства DeepLab [?, ?] побудовані навколо одного алгоритму підвибірки з розширеної просторової піраміди (*англ. Atrous Spatial Pyramid Pooling (ASPP)*) та архітектури енкодер-декодер. ASPP - це модуль для передискретизації карт активації в декількох масштабах до виконання операції згортки. Це дозволяє за одну операцію згортки виділити ознаки в різних масштабах, а також корисний контекст зображення.

Замість того, щоб насправді передискретизувати карти ознак як в PSPNet, зміна масштабу виконується за допомогою фільтрів згортки різного розширення.

Структура блоку ASPP зображена на рисунку 1.16.




Рис. 1.16. Структура блоку ASPP в нейронних мережах DeepLab [?]

Object-contextual Representations Networks.

1.4. Трансферне навчання

Трансферне навчання – це проблема машинного навчання, яка фокусується на збереженні знань, отриманих під час вирішення однієї задачі з подальшим застосуванням її результатів до іншої, але близької до неї.

З практичної точки зору, повторне використання або передача інформації з раніше засвоєних завдань для вивчення нових може значно підвищити ефективність їх розв'язання [savchenko]. Деякі дослідники [1] вважають багатозадачне машинне навчання підмножиною трансферного навчання.

На відміну від трансферного навчання, в багатозадачному навчанні немає різниці між задачами, та завдання стоїть підвищити продуктивність на всіх задачах одночасно.

1.5. Методи багатозадачного глибинного машинного навчання

Багатозадачне машинне навчання - це один з підходів машинного навчання, в якому одночасно вирішуються кілька навчальних задач, використовуючи спільності та відмінності між ними. Кожна з таких задач може бути загальною навчальною задачею, такою як навчання з учителем (наприклад, задача класифікації, або регресії), навчання без вчителя (кластеризація), напіваавтоматичне навчання, завдання навчання з підкріпленням, або моделі на графах. Передбачається, що всі ці навчальні задачі або хоча б частина з них пов'язані одна з одною.

В цьому випадку виявлено [2], що спільне навчання на цих задачах може призвести до значного підвищення продуктивності в порівнянні з навчанням на кожній задачі окремо. Отже, багатозадачне навчання направлено на підвищення якості узагальнення кількох пов'язаних задач. Далі будуть розглядатися виключно задачі контрольованого навчання.

Подібно до людського навчання, корисно вивчати кілька навчальних задач разом, оскільки знання, що містяться в одній задачі, можуть бути використані іншими. Наприклад, людина, що вивчає математику та математичну статистику, може використати цей досвід для вивчення інших схожих галузей, наприклад, машинного навчання.

1.5.1. Визначення багатозадачного машинного навчання. Для n навчальних задач T_1, T_2, \dots, T_n , де всі задачі або їх підмножина пов'язані, багатозадачне навчання (БЗМН) має на меті допомогти покращити вивчення моделі для T_i , використовуючи знання, що містяться в усіх n або деяких з них задачах.

В літературі визначається декілька видів БЗМН:

Однорідне БЗМН: Для кожної з задач прогнозується лише один вихід. Наприклад, розпізнавання цифр MNIST зазвичай використовується для оцінки алгоритмів БЗМН. В цьому разі, воно розглядається як 10 завдань бінарної класифікації.

Неоднорідне БЗМН: Для кожної з задач прогнозується свій набір виходів. Наприклад, сучасні задачі детектування об'єктів потребують одночасного прогнозування класу об'єкта (задача класифікації), його положення на зображенні та розмірів (задача регресії). Для задач контрольованого навчання, кожна задача T_i містить в собі набір даних D_i , що складається з m елементів. . .

Дослідники вважають, що коли різні задачі використовують однакові набори вхідних даних, БЗМН зводиться до задачі класифікації або регресії з кількома виходами. Однак, новіші дослідження визначають БЗМН на одному наборі вхідних даних, або незалежно від кількості наборів вхідних даних.

В методах БЗМН, заснованих на глибоких нейронних мережах, виділяють дві групи відповідно до способу розподілу параметрів між різними задачами.

1.5.2. Жорсткий розподіл параметрів. Зазвичай, архітектури згорткових нейронних мереж для багатозадачного навчання складаються зі спільного енкодера, який виділяє ознаки на вхідному зображенні (shared features), та окремих згорткових і/або повнозв'язних шарів для кожної з

задач.

В найпершій роботі [?], що використовує цей принцип, було запропоновано архітектуру нейронної мережі Task-Constrained Deep Convolutional Network (TCDCN) для детекції ключових точок лиця використати додаткові задачі регресії пози голови та класифікації атрибутів. Архітектуру TCDCN зображено на рис. 1.17.

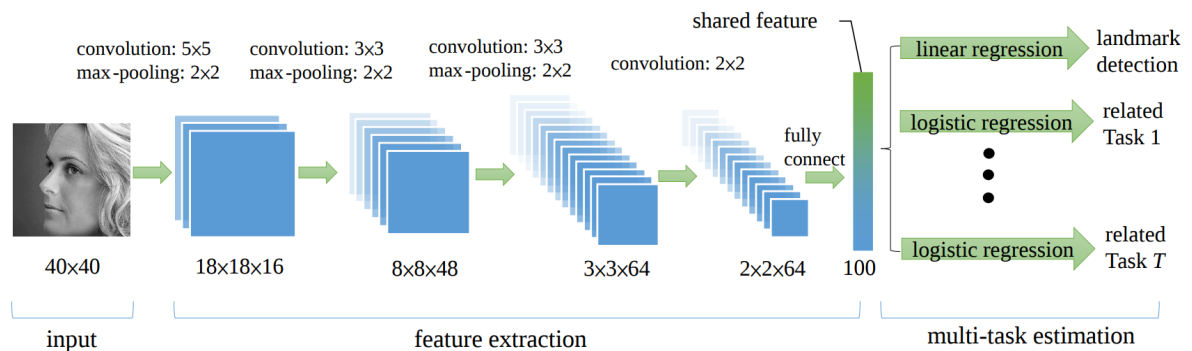


Рис. 1.17. Архітектура нейронної мережі TCDCN [?]

Модифікацією попереднього підходу є багатозадачні каскадні мережі ??, в яких результати одних задач використовуються як доповнення до вхідної інформації для наступних. Така організація шарів дозволяє підвищити точність на більш складних завданнях при правильному підборі черги задач за складністю. Загальну архітектуру зображено на рис. 1.18. Схожий підхід також використовується в деяких архітектурах нейронних мереж для розв'язання задачі детекції об'єктів [?, ?, ?]

Також, можлива інтеграція модулів уваги як до енкодера, так і до специфічних до задачі шарів. Таким чином, обчислення ознак відбувається не лише за рахунок параметрів енкодера, а і через специфічні до задачі модулі, що розташовані всередині мережі. Це дозволяє покращити репрезентації ознак для конкретних задач.

1.5.3. М'який розподіл параметрів. В архітектурах, що використовують м'який розподіл параметрів використовується декілька енкодерів




Рис. 1.18. Архітектура багатозадачної каскадної мережі [?]

для кожної з задач, між шарами яких відбувається обмін інформацією.

Наприклад, в роботі Cross-stitch networks (перехресні мережі)[?] представлена архітектура багатозадачної нейронної мережі, в якій кожній задачі відповідає окремий енкодер, але входом кожного шару кожного з енкодерів є лінійна комбінація виходів попереднього шару всіх енкодерів. Коефіцієнти лінійної комбінації також вивчаються за допомогою градієнтного спуску разом з іншими параметрами нейронної мережі. На рисунку 1.19 зображено архітектуру блоку лінійної комбінації для шарів двох нейронних мереж.

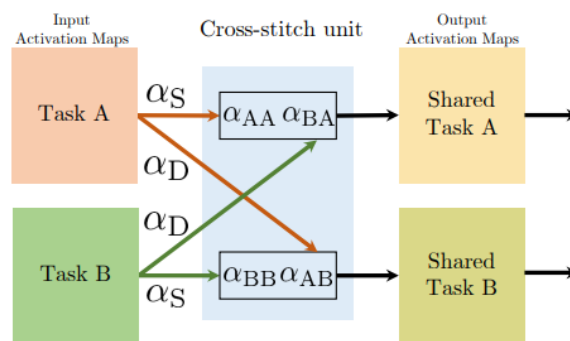


Рис. 1.19. Архітектура cross-stitch блоку [?]

Узагальненням ідеї переносу інформації між послідовними шарами декількох специфічних до задачі нейронних мереж є шлюзові мережі (*англ. Sluice networks*). Вхід до кожного з шарів також є лінійною комбінацією ви-

ходів попередніх шарів для кожної з задач. На відміну від перехресних мереж, кожний шар нейронної мережі розділений на окремі підпростори: для конкретної задачі та спільний між всіма задачами. Також, додається обмеження на ортогональність підпросторів через додавання функції втрат, що мінімізує квадратовану норму Фробеніуса (матричну L^2 норму) між підпросторами в кожному з шарів.

Подальший розвиток шлюзових мереж було запропоновано в роботі «Нейромережеве дискримінативне зменшення розмірності» (англ. *Neural Discriminative Dimensionality Reduction, NDDR*) [?]. Тут, замість використання лінійної комбінації шарів між різними задачами, виконується згортка конкатенованих виходів шарів всіх задач з ядром розміру 1×1 з виконанням подальшої нормалізації. Архітектуру NDDR зображено на рисунку 1.20.

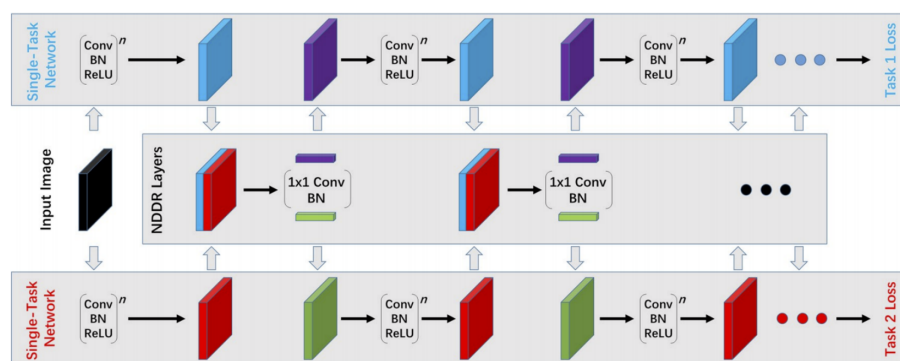


Рис. 1.20. Архітектура згорткової нейронної мережі NDDR [?]

Суттєвим недоліком методів, що використовують м'який розподіл параметрів є постійне збільшення кількості параметрів нейронної мережі, що, в свою чергу, збільшує необхідну кількість ресурсів для роботи такої нейронної мережі зі збереженням продуктивності.

1.5.4. Дистиляція прогнозів моделі. Дистиляція прогнозів замість вивчення ознак, спільних до декількох задач, базується на використанні результатів для одних задач, як засобу вивчення ознак для інших. Наприклад, при одночасному вивченні задач класифікації та сегментації, карти

сегментації можуть бути використані для подальшої класифікації зображення.

Першою роботою, що використала цей принцип була PAD-Net (Prediction-and-Distillation Network) [?]. В ній використовувалися результати задач семантичної сегментації, регресії карти глибини, регресії карти поверхневих нормалей та детекції контурів для отримання уточнених результатів в задачах регресії карти глибини та семантичної сегментації. Для цього автори запропонували три варіанти спеціальних модулів дистиляції:

- ПЕРЕВЕСТИ НОРМАЛЬНО
- Проста конкатенація результатів;
- Передача повідомлень між задачами
- Передача повідомлень з увагою

Подальшим розвитком цього методу стала робота PAP-Net, в якій було представлено модуль, що окремо вивчає попарні взаємозв'язки між задачами, та об'єднує вивчені карти ознак відповідно до попарних відношень.

1.5.5. Багатозадачне навчання в задачах класифікації та сегментації. Використання багатозадачного навчання в задачах класифікації та сегментації не є поширеним в літературі. Зазвичай, в роботах, що пропонують вирішення задачі сегментації, задача класифікації вирішується на етапі попередньої обробки зображень, щоб відсіяти хибнопозитивні результати сегментації та зменшити час роботи системи в цілому через використання легких моделей класифікації. [?, ?, ?] Недоліком такого підходу є можливість поширення помилки від класифікатора, що в задачах скринінгу вимагає підвищення повноти класифікатора, з подальшою роботою сегментаційної мережі. Також, в задачах, що мають маленькі об'єкти на зображеннях, чи незбалансовані набори даних, такий підхід може зменшити влучність роботи системи порівняно з її частинами [?, ?]

На відміну від послідовної обробки, в роботі SegTHOR одночасно розв'язуються задачі класифікації та сегментації, доповнюючи одна одну. Так, автори пропонують нову архітектуру нейронної мережі, що заснована на архітектурі UNet, але має додатковий вихід класифікації з останнього шару мережі сегментації. Отримання глобальних класів з виходу сегментації досягається через середнє арифметичне всіх пікселів для кожного з класів. Архітектура нейронної мережі SegTHOR зображена на рисунку 1.21.




Рис. 1.21. Архітектура методу SegTHOR [?]

В нейронній мережі SegTHOR вихід класифікації використовується лише при тренуванні в якості додаткової задачі, та не використовується під час прогнозування масок сегментації.

В роботі [?] автори запропонували застосувати підхід багатозадачного машинного навчання до класифікації та сегментації новоутворень шкіри. На відміну від звичайних архітектур для сегментації зображень, в роботі запропоновано сегментацію будь-якого новоутворення, з паралельною класифікацією меланому та себорейного кератозу як окремих задач. Автори

показують, що така архітектура нейронної мережі незначно покращує достовірність як в задачах класифікації, так і сегментації. В даній архітектурі під час прогнозування результати різних задач використовуються окремо.

Автори [?] запропонували одночасно вивчати задачі класифікації та сегментації для локалізації ракових пухлин в мамографії. Як і [?], в даній роботі використовується нейронна мережа, що складається з одного енкодера і двох декодерів - для класифікації та сегментації відповідно. Архітектуру нейронної мережі зображено на рисунку ??.




Рис. 1.22. Архітектура нейронної мережі класифікації та сегментації новоутворень на мамографії [?]

В роботі демонструється, що, на відміну від двох нейронних мереж, що вивчають задачі незалежно, запропонована архітектура має більшу точність як класифікації, так і сегментації. В даній архітектурі під час прогнозування результати різних задач використовуються окремо.

Окрім підходів з жорстким розподілом параметрів, в задачі сегментації може використовуватися каскадна схема. В роботі [?] запропоновано архітектуру каскадної нейронної мережі для розв'язання задачі сегментації будівель на аерофотознімках. Для покращення контурів сегментації, в роботі вводиться нова задача регресії піксельної відстані до найближчого контуру. Результат виконання задачі регресії використовується як частина вхідних

даних для задачі сегментації. Архітектуру нейронної мережі зображено на рисунку 1.23. Автори показують, що таке використання декількох задач дозволяє підвищити достовірність сегментації в цілому та якість контурів окремо.




Рис. 1.23. Архітектура нейронної мережі для сегментації будівель [?]

Деякі методи машинного навчання з частковим залученням вчителя використовують архітектури, натхнені багатозадачним машинним навчанням. Так, популярною задачею машинного навчання з частковим залученням вчителя є семантична сегментація зображень з використанням лише міток рівня зображення, точок, або обмежувальних коробок навколо об'єктів. Наприклад, в роботі [?] запропоновано ЕМ-алгоритм сумісно з глибокими нейронними мережами для розв'язання задачі сегментації через тренування нейронної мережі з мітками рівня зображення, або обмежувальних коробок. Задача класифікації в даному випадку використовується на етапі оцінювання очікування в ЕМ алгоритмі як апіорна інформація.

Альтернативний метод сегментації з частковим залученням вчителя базується на функції втрат, що дозволяє одночасно оптимізувати наступні задачі:

- регресію локалізації об'єктів
- розширення локацій об'єктів відповідно до класів, присутніх на зображеннях

— обмеження границь масок сегментації об'єктів до границь об'єктів
Архітектура поєднання задач зображена на рисунку 1.24.

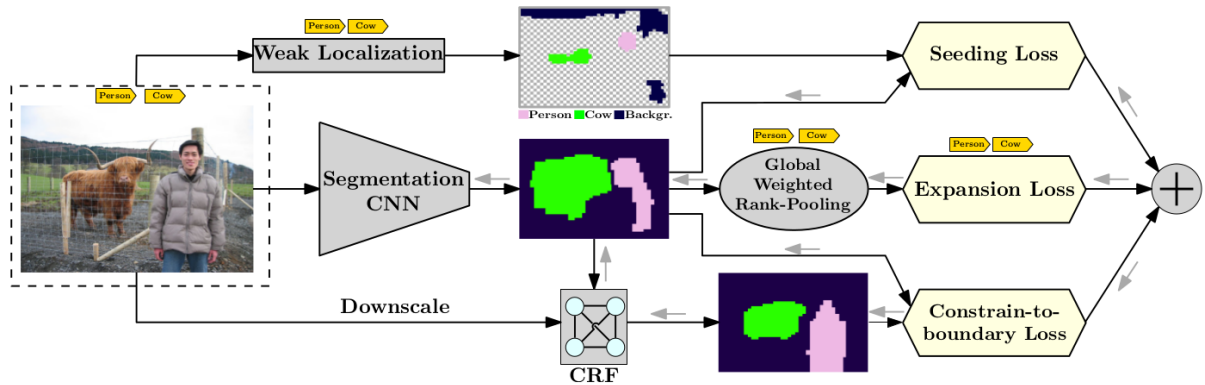


Рис. 1.24. Архітектура методу SEC-CNN [?]

1.6. Аналіз методів оцінки якості класифікації та сегментації зображень в задачі автоматизованого скринінгу

1.6.1. Помилки 1 і 2 роду та матриця невідповідностей. В задачах математичної статистики, помилка першого роду - це хибне відхилення правильної гіпотези (хибно-позитивний результат, FP), тоді як помилка другого роду - це прийняття хибної гіпотези (хибно-негативний результат, FN). Дані поняття використовуються, коли потрібно прийняття бінарного рішення на основі деякого критерію, що може мати похибку.

В задачах контрольованого навчання, зокрема бінарної класифікації, за за нульову гіпотезу зазвичай приймається приналежність елемента вибірки до класу, що зустрічається в виборці частіше. Також, в задачах багатокласової класифікації використовується розширення поняття помилок першого і другого роду на задачу з більшою кількістю гіпотез - матриця невідповідностей. Матриця невідповідностей - це матриця, в строках якої зазначені зразки прогнозованого класу, а кожен із стовпців представляє зразки справжнього класу. Така матриця дозволяє оцінити, чи допускає

система невідповідності між класами.

1.6.2. Влучність, чутливість та специфічність. Влучність, чутливість та специфічність є похідними мірами якості бінарного класифікатора та розраховуються на основі значень в матриці невідповідностей. Влучність (англ. precision) - вимірює частку істинно-позитивних зразків серед знайдених.

$$Precision = \frac{TP}{TP + FP}$$

Чутливість, або повнота (англ. sensitivity, recall) - вимірює частку істинно-позитивних зразків серед усіх позитивних зразків.

$$Recall = \frac{TP}{TP + FN}$$

Специфічність (англ. specificity) - вимірює частку істинно-негативних зразків серед усіх негативних зразків.

$$Specificity = \frac{TN}{TN + FP}$$

Між влучністю і повнотою, та чутливістю і специфічністю існує обернена залежність, коли можливо підвищити одну ціною зниження іншої. Через наявність такої залежності, на практиці, ці міри не використовуються окремо. Замість цього використовують агреговані метрики, що дозволяють оцінити якість класифікатора в цілому.

1.6.3. Міра F1 та індекс подібності Соренсена. F1 та індекс подібності Соренсена (англ. Dice score) є еквівалентними метриками, що, зазвичай використовуються в задачах класифікації (F1) та сегментації (Dice score).

Міра F1 визначається як середнє гармонічне між влучністю та повнотою:

$$F1 = \frac{2}{precision^{-1} + recall^{-1}} = 2 \cdot \frac{precision \cdot recall}{precision + recall} = \frac{2TP}{2TP + FP + FN}$$

Індекс подібності Соренсена визначається на множинах, і, в задачах сегментації, визначається на піксельних масках сегментації:

$$D_c = 2 \cdot \frac{A \cap B}{|A| + |B|}$$

Також, для бінарних даних $A \cap B$ відповідає TP , а $|A| + |B|$ відповідає всій множині об'єктів, тобто еквівалентно $TP + FP + FN$. Таким чином, коефіцієнт Соренсена є еквівалентним мірі F1.

1.6.4. Каппа Коена. Оскільки використання точності неможливе в задачах з сильним дисбалансом класів, значення точності можна перенормувати. Перенормування виконується за допомогою статистики chance adjusted index: точність класифікації нормується з використанням точності, яку можна було б отримати випадково. Під випадковою тут розуміється точність рішення, яке отримано з нашого випадковою перестановкою класів:

$$\kappa = 1 - \frac{\sum_{i=1}^k \sum_{j=1}^k w_{ij} o_{ij}}{\sum_{i=1}^k \sum_{j=1}^k w_{ij} e_{ij}}, \quad (1.10)$$

Де k - це кількість класів, o_{ij} , та e_{ij} це елементи передсказуваних та істинних матриць. w_{ij} розраховується наступним чином для квадратично-зваженої метрики:

$$w_{ij} = \frac{(i - j)^2}{(k - 1)^2}, \quad (1.11)$$

Через чутливість каппи Коена, дослідники повинні ретельно інтерпретувати цю метрику. Наприклад, якщо розглянути дві пари оцінювачів з

однаковим відсотком угоди, але різними пропорціями по класах, це суттєво вплине на значення метрики.

Іншою проблемою є кількість класів: із збільшенням кількості класів, метрика підвищується. Крім того, капша Коена може бути низькою, хоча рівень згоди високий, і окремі оцінки є точними.

Це робить Капшу Коена мінливим коефіцієнтом для аналізу.

1.7. Висновки та постановка задачі дослідження

В першому розділі дисертаційної роботи проведено аналіз методів розпізнавання, класифікації та сегментації планарних зображень, використання для цього методів глибокого навчання, та методів багатозадачного навчання.

Проаналізовано метрики, що використовуються в задачах класифікації та сегментації зображень. Наведено підходи використання багатозадачного навчання для класифікації та сегментації зображень в задачах скринінгу.

Показано, що складність розробки систем автоматизованого скринінгу пов'язана з необхідністю вирішення наступних завдань:

1. Неузгодженість та незбалансованість навчальних наборів даних для задач автоматизованого скринінгу виникає через відносно малу кількість аномальних прикладів в популяціях та значний рівень похибки розмітників. Це створює проблему при навчанні глибоких нейронних мереж стандартними методами. Тому при побудові моделей класифікації та сегментації потрібно вирішувати задачу навчання з урахуванням частково-помилкової розмітки.
2. В задачах автоматизованого скринінгу важливо зменшення кількості хибно-позитивних результатів діагностики, через відносно малу розповсюдженість аномальних прикладів в популяціях та пов'язані з хибно-позитивними результатами подальші дії. Тому, при побу-

дові систем класифікації та сегментації потрібно зосередитися на зменшенні хибно-позитивних результатів.

3. Попередні дослідження показали, що системи автоматизованого скринінгу, засновані на методах багатозадачного глибинного навчання, дозволяють підвищити достовірність класифікації та сегментації за рахунок спільного навчання на цих задачах. Однак, попередні дослідження не враховують можливої комбінації результатів різних задач для підвищення достовірності під час прогнозування. Ці недоліки запропоновано подолати за рахунок комбінування результатів під час фази прогнозування.

4.

У зв'язку з перерахованим вище, сформульовано мету і задачі дослідження.

Метою дисертаційної роботи є підвищення достовірності класифікації та семантичної сегментації планарних зображень без підвищення витрат часу за рахунок розроблення методу об'єднання задач багатозадачного навчання з використанням штучних нейронних мереж.

Для досягнення мети, в роботі виконано наступні задачі:

- Проведено аналіз існуючих методів, алгоритмів та засобів обробки планарних зображень в системах автоматизованого скринінгу
- Удосконалено архітектуру штучної нейронної мережі для багатозадачного навчання
- Розвинуто нейромережевий метод обробки планарних зображень, який за рахунок навчання на декількох задачах одночасно підвищить точність класифікації та семантичної сегментації планарних зображень
- Розроблено метод об'єднання задач класифікації та сегментації на етапі прогнозування, що дозволяє підвищити достовірність класифікації та сегментації без підвищення витрат часу

- Вдосконалено метод сегментації важливих для класифікації ознак зображення в умовах відсутності розмітки семантичної сегментації в навчальному наборі даних
- Проведено випробування розробленого методу та інструментальних засобів в рамках експерименту
- Спроектовано та розроблено інструментальні засоби, що виконують розроблений метод

РОЗДІЛ 2

МЕТОД ГЛИБИННОГО БАГАТОЗАДАЧНОГО НАВЧАННЯ

2.1. Метод багатозадачного навчання ШНМ в умовах частково помилкової розмітки навчального набору даних

2.1.1.

2.1.2.

2.1.3.

2.2. Метод зниження кількості хибно-позитивних прогнозів нейронної мережі за рахунок використання результатів семантично-близьких задач

2.2.1. Використання близьких задач до задачі класифікації.

2.2.2. Використання близьких задач до задачі семантичної сегментації.

2.3. Метод сегментації важливих для класифікації ознак зображення в умовах відсутності розмітки для сегментації в навчальному наборі даних

2.3.1. Комбінування задачі класифікації та сегментації.

2.3.2. Напівавтоматичне навчання ШНМ в задачі сегментації.

2.3.3. Пост-обробка результатів сегментації .

2.3.4. Висновки до другого розділу.

РОЗДІЛ 3

ЕКСПЕРИМЕНТАЛЬНІ ДОСЛІДЖЕННЯ В РІЗНИХ ЗАДАЧАХ СКРИНІНГУ

3.1. Класифікація стадії осередків діабетичної ретинопатії

3.1.1. Опис наборів даних. Використані в цьому експерименті зображень, були взяті з декількох наборів даних. Для претренування нейронних мереж було використано відкритий набір даних від Kaggle: “Diabetic Retinopathy Detection Challenge 2015” dr2015.

Цей набір даних є найбільшим із загальнодоступних. Він складається з 35126 фотографій очного дна для лівого та правого ока американських громадян, з розміченими стадіями діабетичної ретинопатії за стандартним протоколом:

- Відсутність діабетичної ретинопатії (мітка 0)
- Легка діабетична ретинопатія (мітка 1)
- Помірна діабетична ретинопатія (мітка 2)
- Важка діабетична ретинопатія (мітка 3)
- Проліферативна діабетична ретинопатія (мітка 4)

Крім того, були використані менші набори даних: набір зображень індійської діабетичної ретинопатії (IDRiD) idrid, з якого використано 413 фотографій очного дна, та MESSIDOR (Методи оцінки методів сегментації та індексації в області офтальмології сітківки) messidor, з якого використано 1200 фотографій очного дна. Оскільки розмітка оригінального набору даних MESSIDOR відрізняється від інших наборів даних, ми використали версію, яку група офтальмологів messidor_relabeled помаркувала відповідно до стандартного протоколу.

Усі зазначені набори даних мають однаковий розподіл міток класів, що є фундаментальною властивістю для цієї задачі.

Оцінка проводиться на наборі даних Kaggle APTOS2019 aptos2019, дослідники мають доступ лише до тренувальної та валідаційної частин. Повний набір даних складається з 18590 фотографій очного дна, які розділені на набори з 3662 тренувальних, 1928 валідаційних та 13000 тестових зображень, що були розділені організаторами змагань Kaggle.

3.1.2. Детальний опис структури нейронної мережі.

3.1.3. Детальний опис процедури навчання.

3.1.3.1. Ініціалізація нейронної мережі. Відпочатку, енкодер ініціалізується параметрами нейронної мережі, що була натренована на наборі даних ImageNet. Параметри декодерів ініціалізуються випадково (ініціалізація X_e).

3.1.3.2. Трансферне навчання. Використання трансферного навчання можливо, оскільки природні особливості діабетичної ретинопатії узгоджуються між різними людьми і не залежать від набору даних. Крім того, різні набори даних збираються на різному обладнанні. Включення цих знань у модель підвищує її здатність до узагальнення та підвищує важливість природних ознак за рахунок зменшення чутливості до особливостей обладнання.

Для попереднього навчання, ініціалізована нейронна мережа навчається на протязі 20 епох на наборі даних DRDC2015 за допомогою стохастичного градієнтного спуску. Основна мета попереднього навчання - створити ініціалізацію параметрів на розподілі даних, що є близьким до цільового. Після попереднього навчання, параметри нейронної мережі використовуються як ініціалізація для основного навчання.

Під час попереднього навчання, кожен декодер мінімізує свою функцію втрат: перехресну ентропію для класифікаційного декодера, бінарну перехресну ентропію для декодера порядкової регресії та середню абсолютну похибку для декодера регресії.

Основне тренування проводиться на наборах даних APTOS2019, IDRID та MESSIDOR разом. Починаючи з ваг, отриманих на етапі попереднього тренування, виконується 5-кратна перехресна перевірка та оцінка моделі на відкладеному наборі даних. На цьому етапі функції втрат для декодерів змінено: Focal loss focalloss для класифікаційного декодера, бінарна Focal loss focalloss для декодера порядкової регресії та середньоквадратична помилка для декодера регресії.

Зміна функцій втрат на даному етапі пов'язана з необхідністю знизити значення втрат для зразків, що вже коректно класифіковані, щоб зменшити вплив ознак, що не відносяться до захворювання.

Для кожної з підвибірок було натреновано одну модель, протягом 75 епох, використовуючи алгоритм оптимізації Rectified Adam, radam, зі змінною темпу навчання за косинусним законом. Щоб зберегти параметри енкодера, поки декодери перебувають у випадковому стані, оновлення параметрів енкодера не відбувається на протязі перших п'яти епох навчання.

3.1.3.3. Комбінування результатів декількох задач. На етапі після основного навчання, для кожної з моделей, навчається модель лінійної регресії з виходів декодерів в єдине значення.

Лінійна регресія навчається після основного навчання, оскільки в іншому випадку, сходиться до неоптимальних локальних мінімумів з вагами двох декодерів, близьких до нуля. Ці нульові ваги запобігають оновленню відповідних ваг декодерів і, відповідно, запобігають навчанню. Початкові ваги для кожного з виходів декодерів були встановлені рівними $1/3$, а потім тренувались протягом п'яти епох, щоб мінімізувати середньоквадратичну

функцію помилки.

3.1.3.4. Результати експерименту.

3.2. Класифікація раку шкіри та сегментація родимок

3.2.1. Опис набору даних SIIM-ISIC Melanoma Classification.

Дані зображень, використані в цьому дослідженні, були взяті з декількох наборів даних з однаковою структурою: SIIM&ISIC з 2017, 2018, 2019 та 2020 років. Ці набори даних були створені Міжнародною співпрацею з обробки зображень шкіри (англ. International Skin Imaging Collaboration - ISIC), а зображення отримані з наступних джерел:

- лікарня Клінік де Барселона
- Віденський медичний університет
- Центр раку Меморіал Слоун Кеттерінг
- Австралійський інститут меланоми
- Квінслендський університет
- Афінська медична школа

Загалом, ці набори даних складаються із приблизно 50000 RGB-зображень, з яких близько 3000 мають зображення злоякісних уражень. Набір даних містить 434 повторюваних зображення. Окрім даних про зображення, були надані метадані про пацієнтів. Один пацієнт має декілька зображень різних родинок.

Зображення та метадані надані у форматі DICOM, який є загальнозживаним форматом даних медичних зображень. Крім того, набір даних доступний у форматі JPEG із розмірами зображень, змінених до 1024x1024. Метадані також надаються за межами формату DICOM, у файлах CSV [12].

Метадані містять наступну інформацію:

- `image_name` - унікальний ідентифікатор, вказує на ім'я файлу відповідного зображення DICOM;
- `patient_id` - унікальний ідентифікатор пацієнта;
- `sex` - стать пацієнта;
- `age_approx` - приблизний вік пацієнта на момент фотографії (ціле число);
- `anatom_site_general_challenge` - розташування родинки на тілі;
- `diagnosis` - детальна інформація про діагностику (рядок);
- `benign_malignant` - показник злоякісності зображеного ураження (`cnhjrf`, одна з `"benign"` і `"malignant"`);
- `target` - бінарізована версія цільової змінної.

Значення для `anatom_site_general_challenge` та `diagnosis` беруться із заздалегідь визначеного кінцевого набору.

Метадані доступні для кожного пацієнта, тому різні зображення можуть мати однаковий набір функцій рівня пацієнта. Ми використовуємо всі доступні метадані, крім ідентифікатора пацієнта та діагностики, оскільки вони доступні лише в навчальних наборах даних.

Набір даних має дисбаланс високого класу. Розподіл діагнозів показано на рис. 1. Для значень `unknown` в полі `diagnosis`, автори набору даних гарантують, що новоутворення не є злоякісним [13].

Через те, що зображення в наборі даних з різних джерел та мають різні стандарти візуалізації вони мають структурований шум у вигляді лінійних смуг, областей, позначених ручкою, центруючих ліній тощо. Залежно від місця новоутворення та статі, також спостерігається волосся. Всі ці додаткові ознаки можуть значно вплинути на тренувальний процес і можуть призвести до перенавчання.

3.2.2. Детальний опис структури нейронної мережі.

3.2.3. Детальний опис процедури навчання. В даному експерименті використано одноступеневий навчальний процес, який включає одночасно трансферне навчання та багатозадачне навчання.

Навчання проводиться у 3-кратній схемі перехресної перевірки. Енкодер відпочатку ініціалізується за допомогою вагів, отриманих за допомогою алгоритму [25]. У наших експериментах ми спостерігали, що така ініціалізація призводить до стабільно кращих результатів, ніж ініціалізація Imagenet.

3.2.4. Результати експерименту.

3.3. Класифікація та сегментація формацій хмар

3.3.1. Опис набору даних Understanding Clouds from Satellite Images. Набір даних Understanding Clouds from Satellite Images (UCSID) складається з 10000 RGB зображень, зроблених з двох супутників TERRA та AQUA, що знаходяться на полярній орбіті [6]. Кожен з цих супутників проходить над певну область один раз на день. Через обмежене поле зору камер, встановлених на цих супутниках, кожне зображення зшито з двох супутників, що знаходяться над однією й тою самою областю одночасно, але на різних орбітах. Решта зображення, для якої не було знято даних під час прольоту супутників (між орбітами) заповнена чорним кольором. Оскільки зображення підлягають компресії, є артефакти стиснення, та чорний колір має деякі незначні аномалії.

На знімках є регіони, які містять певні хмарні утворення, та помічені дослідниками відповідно: Риба, Квітка, Гравій, Цукор (англ. Fish, Flower, Gravel, Sugar). Кожне зображення має принаймні одне хмарне утворення і може містити до всіх чотирьох одночасно.

Розмітка для цих регіонів була створена під час краудсорсингу в Інституті метеорології імені Макса Планка в Гамбурзі, Німеччина, та Laboratoire de météorologie Dynamique у Парижі, Франція. Команда з 68 вчених

виявила ділянки з хмарами на кожному зображенні, і кожне зображення було розмічене, в середньому, трьома різними вченими. Кожен вчений мав виділити хмари за допомогою прямокутних областей на власний розсуд. Основна розмітка була створена об'єднанням областей, що були розічені всіма вченими для цього зображення, після видалення чорної смуги з цих областей [7].

Через те, як був зібраний UCSID, він має значну кількість пікселів шуму масках для хмар. Оскільки маски складаються з прямокутників, які повністю перекривають хмару, існує багато пікселів, які позначені як хмари, але, насправді, відповідають фону. Також, не всі хмари позначені масками. Через об'єднання масок від різних анотаторів, класи можуть суттєво перекриватися, включаючи випадки, коли всі чотири класи присвоюються одним і тим самим пікселям.

Усі зображення мають вихідну роздільну здатність 2100x1400 пікселів. Більшість зображень містять більше ніж один клас хмар. Немає зображень без хмар. Розподіл класів хмар на зображеннях показано на рисунку.

Різні типи хмар зазвичай зустрічаються разом, розподіл комбінацій різних типів хмар зазначено на рисунку. UCSID розділено на 5546 тренувальних, та 3698 валідаційних зображень. Крім того, немає доступу до міток валідаційного набору даних. Значення метрики можливо отримати через систему валідації.

До розподілу міток класів в наборі даних не було виконано змін (недискретизація, передискретизація тощо).

3.3.2. Детальний опис структури нейронної мережі.

3.3.3. Результати експерименту.

РОЗДІЛ 4

ІНСТРУМЕНТАЛЬНІ ЗАСОБИ

- 4.1. Узагальнена структура системи автоматизованого скринінгу
- 4.2. Узагальнена структура системи навчання глибоких нейронних мереж
- 4.3. Узагальнена структура прогнозування за допомогою глибоких нейронних мереж
- 4.4. Апробація результатів дисертаційного дослідження

ВИСНОВКИ