

## АНОТАЦІЯ

*Тимченко Б. І.* Нейромережеві методи аналізу планарних зображень в системах автоматизованого скринінгу. — Кваліфікаційна наукова праця на правах рукопису.

Дисертація на здобуття наукового ступеня доктора філософії за спеціальністю 122 — Комп'ютерні науки. — ІКС ОНПУ, Одеса, 2021.

У **вступі** обґрунтовано актуальність удосконалення систем автоматизованого скринінгу (виявлення та класифікація нетипових об'єктів або процесів) шляхом створення моделей наборів даних та методів їх генерації, а також моделей нейронних мереж та методів багатозадачного навчання з метою підвищення достовірності класифікації та сегментації планарних зображень без підвищення витрат часу. Визначено об'єкт, предмет, задачі і методи дослідження; показано зв'язок з науковими програмами та планами; наведено наукову новизну та практичне значення одержаних результатів; висвітлено особистий внесок здобувача.

В **першому розділі** дисертаційної роботи проведено аналіз проблем аналізу планарних зображень (які не мають виміру глибини, та в яких можна знехтувати масштабом об'єктів) в системах автоматизованого скринінгу на основі нейромережевих технологій.

Проаналізовано існуючі системи автоматизованого скринінгу в предметних областях медицини, метеорології та віддаленого зондування та особливості функціонування систем автоматизованого скринінгу на основі планарних зображень. Показано, що ефективність роботи таких систем безпосередньо залежить від достовірності класифікації та сегментації зображень, оскільки хибно-позитивні результати можуть призвести до передчасного

реагування, а хибно-негативні результати - до пропуску наявних проблем та пізнього реагування. Крім того, не менш важливим фактором, що впливає на ефективність скринінгових систем є витрати часу на реалізацію процесу навчання за обраною моделлю, що в свою чергу пов'язано з якістю попередньо створених навчальних вибірок даних. Але для вирішення задач аналізу планарних зображень в скринінгових системах, отримання великої кількості попередньо маркованих (розмічених) якісних даних навчальних вибірок є дуже дорогим, та іноді не є можливим в принципі через малу кількість прикладів, різноманіття зовнішнього вигляду та неузгодженість розмітників (через складність процесу розмітки, непрофесіоналізм, тощо) під час формування розмітки в наборах даних. Ці фактори негативно відображаються на достовірності класифікації та сегментації при навчанні глибинних нейронних мереж стандартними методами. Для її розв'язання запропоновано при побудові моделей класифікації та сегментації вирішити задачу навчання з урахуванням частково-помилкової розмітки.

Показано, що в таких умовах доцільне використання глибинних нейронних мереж, через можливість автоматизації процесу навчання. Також, використання глибинних нейронних мереж дозволяє організацію багатозадачного глибинного навчання, що може підвищувати достовірність класифікації.

Проведений аналіз наявних моделей наборів даних та методів їх генерації показав обмеженість моделей наборів даних, які б дозволяли змінювати рівень зашумлення розмітки відповідно до характеристик зашумлення в реальних наборах даних.

Таким чином, вирішення важливої науково-технічної задачі підвищення достовірності класифікації та сегментації в задачах аналізу планарних зображень шляхом удосконалення моделей нейронних мереж та методів їх багатозадачного навчання, особливо за умови частково-помилкової розмітки даних навчальної вибірки.

У **другому розділі** розроблено метод генерації наборів даних для забезпечення можливості тестування нейронних мереж при навчанні з використанням зашумленої розмітки та запропоновано параметричну формалізацію моделі зашумлених наборів даних.

Оскільки одержання достовірної розмітки класифікації та сегментації для тестувальних вибірок часто є неможливим або дуже затратним, запропоновано використання модельних наборів даних для оцінки достовірності моделей та методів навчання глибоких нейронних мереж. Такі набори даних дають можливість проводити навчання та тестування в контрольованих умовах шляхом зашумлення розмітки навчальної вибірки даних (як правило, тестова вибірка залишається з точною розміткою).

Запропонована модель набору даних  $\mathcal{M}$  має наступне представлення:

$$\mathcal{M} \in \{\mathcal{X}_b, \mathcal{X}_{tex}, N, S_{img}, S_{obj}, \Delta_{max}, N_{obj}, P_e, P_d, S_e, S_d\} \quad (1)$$

де  $\mathcal{X}_b$  - набір зображень фону,  $\mathcal{X}_f$  - набір об'єктів,  $\mathcal{X}_{tex}$  - набір зображень текстур об'єктів,  $N$  - кількість зображень в генерованому наборі даних,  $S_{img}$  - розмір генерованих зображень в пікселях,  $S_{obj}$  - середній розмір об'єкта в пікселях,  $\Delta_{max}$  - максимальне відхилення розміру об'єкта в відсотках,  $N_{obj}$  - максимальна кількість об'єктів на зображенні,  $P_e$  та  $P_d$  - ймовірності зменшення та збільшення маски кожного з об'єктів,  $S_e$  та  $S_d$  - допустимі масштаби збільшення та зменшення масок всіх об'єктів.

Останні чотири параметри введено для створення контрольованого зашумлення розмітки.

Введення цих параметрів дозволяє створити контрольоване зашумлення розмітки відповідно до реальних характеристик.

Сформульовано **перший пункт наукової новизни**: вперше запропоновано параметричну формалізацію моделі набору даних із частково-помилковою розміткою, яка характерна для реальних задач автоматизова-

ного скринінгу, що дозволило розробити метод генерації навчальних, тестових та валідаційних наборів даних.

На основі запропонованої параметричної моделі (1) розроблено метод генерації наборів даних із зашумленою розміткою, який містить наступні кроки:

1. Вибрати випадкове зображення фону:  $x_{bg} \sim \mathcal{X}_b$
2. Вибрати кількість об'єктів на зображенні:  $N_{obj} \sim \mathcal{U}(1, N_{obj})$
3. Провести ініціалізацію маски сегментації:  $M = 0$  так що  $M \in \mathcal{R}^{C \times S_{img} \times S_{img}}$
4. Виконати наступні кроки  $n_{obj}$  разів:

4.1 Вибрати розміри об'єкта:  $s \sim \mathcal{U}(S_{obj} - \Delta_{max}, S_{obj} + \Delta_{max})$

4.2 Вибрати координати розміщення об'єкта:

$$i_f \sim \mathcal{U}(0, S_{img} - s)$$

$$j_f \sim \mathcal{U}(0, S_{img} - s)$$

4.3 Вибрати зображення об'єкта  $x_{fg} \sim \mathcal{X}_f$  та відповідний клас об'єкта  $c_{fg} \sim \mathcal{Y}_f$

4.4 Змінити розмір зображення об'єкта за допомогою білінійної інтерполяції:

$$\hat{x}_{fg} = R_{bilinear}(x_{fg})$$

4.5 Вибрати зображення текстури  $x_{tex} \sim \mathcal{X}_{tex}$

4.6 Модифікувати зображення об'єкта за допомогою текстури:

$$\hat{x}_{fg} = x_{fg} \circ x_{tex}[i_f : i_f + s, j_f : j_f + s]$$

4.7 Розмістити зображення об'єкта на зображенні фону:

$$x_{bg}[i_f : i_f + s, j_f : j_f + s] = (1 - x_{fg}) \circ x_{bg} + \hat{x}_{fg}$$

4.8 Сформувати маску сегментації об'єкта:

$$M_{seg} = x_{fg} > \theta_{seg}$$

де  $\theta_{seg}$  - поріг бінаризації вихідного зображення об'єкта. Для набору даних MNIST  $\theta_{seg} = 0.2$ , для набору даних FashionMNIST  $\theta_{seg} = 0.1$ .

4.9 Модифікувати маску сегментації відповідно до необхідного рівня помилок:

$$M_{seg} = \begin{cases} M_{seg} \oplus K^{S_d \times S_d} & \text{якщо } p_d \sim \mathcal{U}(0, 1) < P_d \\ M_{seg} \ominus K^{S_e \times S_e} & \text{якщо } p_e \sim \mathcal{U}(0, 1) < P_e \end{cases}$$

де  $K^{S_d \times S_d}$  - матриця ядра  $K^{S_e \times S_e}$  - матриця ядра ерозії.

4.10 Розмістити модифіковану маску сегментації об'єкта на загальному зображенні маски сегментації:

$$M[c_{fg}, i_f : i_f + s, j_f : j_f + s] = \max \{M[c_{fg}, i_f : i_f + s, j_f : j_f + s], M_{seg}\}$$

4.11 Зберегти зображення  $x_{bg}$  та маску  $M$

## 5. Завершити генерацію

Таким чином, удосконалено метод генерації наборів даних із зашумленою розміткою на основі параметричної моделі, що за рахунок генерації зашумленої розмітки для тренувальної вибірки та незашумленої розмітки - для тестової, дало можливість виконувати тестування впливу зашумлення розмітки на роботу нейромережових методів сегментації та класифікації.

Метод дозволяє отримати безліч наборів даних із схожими характеристиками та використовувати непараметричні статистичні методи (бутстрепінг) для оцінки моделей в умовах відсутності реальних тренувальних даних. Метод становить **другий пункт наукової новизни**.

В **третьому розділі** дисертаційної роботи розроблено моделі нейронних мереж та методи багатозадачного навчання для одночасного підвищення достовірності класифікації та сегментації без підвищення витрат часу.

Для реалізації методів багатозадачного навчання, запропоновано удосконалити моделі глибинних нейронної мережі з використанням архітектури енкодер-декодер (UNet, LinkNet) введенням додаткового декодера. Та-

ким чином, вдосконалена модель складається з енкодера та двох декодерів (для задач сегментації та класифікації відповідно).

Модель глибокої нейронної мережі представлено наступним виразом:

$$v_1, v_2 \dots v_n = F_{encoder}(x, \theta_{enc}) \quad (2)$$

$$M_{seg} = F_{seg}((v_1, v_2 \dots v_n), \theta_{seg}) \quad (3)$$

$$C_{cls} = F_{cls}((v_n), \theta_{cls}) \quad (4)$$

де  $\theta_{enc}$  - набір параметрів енкодера,  $\theta_{seg}$  та  $\theta_{cls}$  - набори параметрів декодерів сегментації та класифікації відповідно,  $F_{seg}$  та  $F_{cls}$  - нейронні мережі декодера сегментації та класифікації відповідно. Запропонована модель складає **третій пункт наукової новизни**.

Завдяки введенню додаткового декодера класифікації, з'явилася можливість реалізації методів багатозадачного навчання глибоких нейронних мереж та передбачення результатів.

При практичному використанні нейромережових методів в задачах скринінгу встановлено, що частково-помилкова розмітка тренувальних даних запобігає отриманню високої достовірності в задачах класифікації та сегментації. Запропоновано метод багатозадачного навчання нейронних мереж в умовах частково-помилкової розмітки навчальних даних спирається на використання задач, похідних від оригінальної. Показано, що для задачі сегментації існує близька більш загальна задача класифікації, для якої розмітка навчальних даних є більш влучною, ніж для вихідної задачі сегментації.

В такому контексті, задача класифікації зводиться до задачі навчання за набором зразків: замість розмітки кожного з об'єктів для всіх класів на зображенні, зображення являє собою мішок з одним, чи декількома об'єктами та відповідним маркуванням, чи є об'єкти заданих класів на зображенні.

На відміну від попередніх методів, що спираються на вивчення більш детальних близьких задач, в запропонованому методі використання більш точних даних, для загальніших задач дозволяє покращити роздільність внутрішніх представлень нейронної мережі, що, в свою чергу, покращує результати на вихідній задачі. Також, оскільки задачі є близькими, не відбувається конфлікту градієнтів, що є типовим при навчанні різнорідних задач.

Для кожної з задач окремо обчислюється функція втрат. Для навчання декодера сегментації використовується обмежена зверху функція втрат, в той час як для декодера класифікації - звичайна. Загальне значення функції втрат визначається як арифметичне середнє між індивідуальними значеннями:

$$L_{total} = \frac{L_{seg} + L_{cls}}{2} \quad (5)$$

Відповідно, загальний градієнт функції втрат буде сумою градієнтів складових частин:

$$\nabla L_{total} = \frac{\nabla L_{seg} + \nabla L_{cls}}{2} \quad (6)$$

Таким чином, забезпечується "прохід" градієнтів для оновлення параметрів від хоча б однієї функції втрат для кожного вхідного прикладу.

Для зменшення впливу помилкової частини розмітки, запропоновано зміну до методу оцінки при навчанні нейронних мереж: введено обмеження другого роду (зверху) на функцію втрат для задачі з менш точною розміткою, таким чином, при навчанні на декількох задачах, градієнти від неправильної розмітки не впливають на процес навчання:

$$\mathcal{L} = \min(L, \theta)$$

де  $\theta$  - поріг обмеження функції втрат.

Для функції обмеження зверху градієнт визначено лише на проміжку  $(-\infty, \theta]$ , тому для проміжку  $(\theta, \infty)$  градієнт встановлено рівним нулю:

$$\nabla \min(L, \theta) = \begin{cases} 1 & L \in (-\infty, \theta] \\ 0 & L \in (\theta, \infty) \end{cases}$$

На основі запропонованих моделі нейронної мережі та методу її навчання, розроблено метод об'єднання близьких задач на етапі прогнозування, для того, щоб підвищити достовірність класифікації та сегментації планарних зображень без підвищення витрат часу.

Нехай  $C_{cls} \in \mathcal{R}^C$  та  $M_{seg} \in \mathcal{R}^{C \times H \times W}$  - результати декодерів класифікації та сегментації відповідно, значення яких знаходяться на проміжку  $(-\infty, +\infty)$  (логіти).

Для отримання результатів на проміжку  $[0, 1]$  використовується логістична сигмоїдна функція активації:

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

Запропонований метод полягає у зважуванні карти сегментації за допомогою нормованих логітів класифікатора. Першим кроком є трансформація логітів сегментації та класифікації в некалібровані оцінки на проміжку  $[0, 1]$ :

$$\begin{aligned} \hat{M}_{seg} &= \sigma(M_{seg}) \\ \hat{C}_{cls} &= \sigma(C_{cls}) \end{aligned}$$

Ці оцінки мають ті самі розмірності, що й оригінальні маска та класи, для зручності репрезентації операцій додано додаткові розмірності до вектору класів:  $\hat{M}_{seg} \in \mathcal{R}^{C \times H \times W}$  та  $\hat{C}_{cls} \in \mathcal{R}^{C \times 1 \times 1}$



Зважування карти сегментації відбувається за допомогою добутку Адамара між матрицями  $\hat{M}_{seg}$  та  $\hat{C}_{cls}$

$$M_{refined} = \hat{M}_{seg} \circ \hat{C}_{cls}$$

Для покращення можливостей інтерпретації прогнозів моделей, було вдосконалено метод локалізації важливих для класифікації ознак зображення за рахунок використання методів багатозадачного навчання, що дозволило його використання в умовах відсутності розмітки сегментації в навчальному наборі даних.

В основі запропонованого методу лежить ітеративне уточнення карти ознак локалізації за допомогою направлення градієнтів від задачі класифікації:

Обчислюється уточнена ознак класифікації шляхом добутку Адамара між нормованим за допомогою сигмоїдної функції виходом декодера сегментації та логітами класифікації:

$$M_{unsup} = \hat{M}_{seg} \circ C_{cls} \quad (7)$$

Далі, для отримання результату класифікації виконується сумація елементів  $M_{unsup}$  з нормалізацією за сумою елементів оригінальної ненормалізованої карти локалізації:

$$C_{unsup} = \frac{\sum_{h=0}^H \sum_{w=0}^W M_{unsup}(h,w)}{\sum_{h=0}^H \sum_{w=0}^W M_{seg}(h,w) + c} \quad (8)$$

За допомогою моделі протестовано запропоновані методи в різних умовах, виконаний аналіз внеску окремих компонентів та проведено аналіз стійкості запропонованого методу до різних рівнів зашумлення розмітки. В середньому, підвищення коефіцієнта Дайса відносно базової моделі склало 13%. Для високих рівнів зашумлення, підвищення склало 42%.

Таким чином, можна сформулювати **четвертий пункт наукової новизни**, а саме удосконалено методи багатозадачного навчання штучних нейронних мереж та передбачення результатів, що за рахунок об'єднання задач класифікації та сегментації, і введення обмеження другого роду (зверху) до функції втрат для задач з менш точною розміткою, дозволило підвищити достовірність сегментації умовах частково помилкової розмітки навчального набору даних в задачах автоматизованого скринінгу.

У **четвертому розділі** розроблені інструментальні засоби, що реалізують запропоновані рішення. Проведено випробування розробленого методу в рамках експериментів як на синтетичних даних, що були згенеровані за допомогою запропонованої моделі, а також експерименти в реальних задачах: скринінг діабетичної ретинопатії, скринінг меланоми, та скринінг хмарних утворень.

Інструментальні засоби розроблено мовою програмування Python з використанням фреймворку автоматичного диференціювання PyTorch. На основі розроблених інструментальних засобів створено ефективні програмні модулі, які інтегровано з “хмарними” сервісами для вирішення ресурсомістких задач навчання нейронних мереж, що забезпечує високу обчислювальну потужність та швидкість прогнозування в задачах автоматизованого скринінгу.

Для задачі автоматизованого скринінгу при сегментації патернів організації хмар на супутникових знімках (в рамках проекту “Understanding Clouds from Satellite Images” на платформі для змагань з наук про дані Kaggle) було використано запропоновані моделі нейронних мереж, а також методи їх навчання та прогнозування результатів. Підвищення достовірності (міра Дайса) відносно базової моделі склало 3.9%.

Для задачі автоматизованого скринінгу при класифікації стадій діабетичної ретинопатії (в рамках проекту “APTOS 2019 Blindness Detection” на платформі для змагань з наук про дані Kaggle) було використано запро-

поновані методи багатозадачного навчання та прогнозування результатів. Підвищення достовірності (F1-міра) відносно базової моделі склало 2.1%.

Для задачі розпізнавання уражень шкіри при скринінгу меланоми (у рамках проекту SIIM-ISIC Melanoma Classification на платформі для змагань з наук про дані Kaggle) було використано запропонований локалізації важливих для класифікації ознак зображення. Використання запропонованого методу дозволило спростити процес контролю навчання нейронних мереж, що допомогло попередити перенавчання і підвищити достовірність класифікації на 3.5%.

Розроблені в роботі методи та інструментальні засоби отримали впровадження в навчальний процес ОНПУ та програмний продукт SafetyRadar компанії VITech Lab, основним призначенням якого є скринінг наявності елементів засобів індивідуального захисту на людях в умовах будівельних майданчиків, або лікарень та лабораторій.

*Ключові слова:* аналіз зображень, модель даних, глибинні нейронні мережі, багатозадачне машинне навчання, сегментація, класифікація, функції втрат.

## ВСТУП

**Актуальність теми** зумовлюється стрімким розвитком процесів, які потребують швидкого реагування на нетипові зміни для їх подальшого коригування, поки ціна наслідків є низькою. Задача виявлення таких нетипових змін називається задачею скринінгу, особливу групу серед яких складають задачі, основані на аналізі планарних зображень, які виникають, наприклад, при медичній діагностиці, дистанційному зондуванні Землі, метеорології тощо. Автоматизація скринінгу дозволяє з більшою ефективністю вирішувати проблеми підвищення продуктивності діяльності людини-оператора, підвищити рентабельність відповідних процесів.

При автоматизації скринінгу основними процедурами, що визначають його достовірність є сегментація регіонів інтересу та їх класифікація. Традиційно, в таких системах використовуються класичні методи комп'ютерного зору (пошук границь, бінарна сегментація за інтенсивністю, кореляційно-екстремальний метод, тощо), однак достовірність їх суттєво обмежена через різноманіття можливих проблем та складність їх формалізації за допомогою наборів простих ознак. В таких умовах доцільно використання класифікаційного методу сегментації (англ. semantic segmentation), для яких в теперішній час використовуються глибокі нейронні мережі, через можливість автоматизації процесу навчання. Також, перевагою нейромережових методів є можливість проводити донавчання в автоматичному режимі, що дозволяє їх використання для різноманітних видів задач з різних предметних областей.

Однак, відомі підходи на основі глибоких нейронних мереж можуть бути застосовані виключно за умови наявності великих тренувальних наборів розмічених даних. Часто, в задачах скринінгу, отримання великої кількості

даних, а також якісної розмітки від професіоналів є дуже дорогим, та іноді не є можливим в принципі через малу кількість прикладів, різноманіття зовнішнього вигляду та неузгодженість розмітників під час формування розмітки в наборах даних. Ще одним шляхом до підвищення достовірності глибинних нейронних мереж є використання багатозадачного навчання, але його застосування потребує додаткової розмітки тренувальних даних.

Таким чином, має місце **протиріччя** між високими вимогами щодо достовірності нейромережових методів в системах автоматизованого скринінгу з одного боку, та необхідністю навчання нейронних мереж з урахуванням частково-помилкової розмітки тренувального набору даних.

Для розв'язання цього протиріччя в дисертаційній роботі “Нейромережові методи аналізу планарних зображень в системах автоматизованого скринінгу” запропоновані відповідні нейромережові моделі та методи. Розв'язання протиріччя, яке вирішується в роботі, зумовлює актуальність розробки та удосконалення нейромережових моделей та методів аналізу планарних зображень в задачах автоматизованого скринінгу для підвищення його достовірності.

**Робота пов'язана з дослідними проектами:** № 700-145 «Моделі, методи та інструментальні засоби підтримки прийняття рішень з підвищення ефективності гідроаеродинамічних процесів в діючому енергетичному обладнанні» (№ ДР 0115U000413); № 448-68 «Дослідження інформаційних сховищ як моделей предметних областей в системах підтримки прийняття рішень» (№ ДР 0104U002401); № 37-62 «Методи моделювання та робочого діагностування складних цифрових систем і мереж» (номер ДР 0110U008194)

**Метою дослідження** є підвищення достовірності класифікації та сегментації планарних зображень в системах автоматизованого скринінгу шляхом розробки моделі та методів аналізу планарних зображень на основі штучних нейронних мереж. Для досягнення мети дослідження поставлено

і розв'язано такі задачі:

- здійснено аналіз зашумлення розмітки в наборах даних для задач автоматизованого скринінгу, проведено аналіз існуючих моделей, методів, алгоритмів та засобів аналізу планарних зображень в системах автоматизованого скринінгу і обґрунтовано вибір напрямку досліджень.
- на основі проведеного аналізу розроблено параметричну модель набору даних, що складається з планарних зображень із зашумленою розміткою для задач класифікації та сегментації, а також метод його генерації.
- розроблено модель нейронної мережі та методи навчання й передбачення для аналізу планарних зображень, що за рахунок використання декількох близьких задачах одночасно дозволяють підвищити точність класифікації та сегментації в умовах зашумлення розмітки даних.
- розроблено інструментальні засоби, що виконують розроблені моделі та методи, і проведено їх випробування в рамках експерименту

**Об'єктом дослідження** є процес аналізу планарних зображень.

**Предмет дослідження** – методи класифікації та сегментації планарних зображень, структури та моделі згорткових нейронних мереж та методи їх навчання.

**Наукова новизна** отриманих результатів.

- *вперше* запропоновано параметричну формалізацію моделі набору даних із частково-помилковою розміткою, яка характерна для реальних задач автоматизованого скринінгу, що дозволило розробити метод генерації навчальних, тестових та валідаційних наборів даних.
- *удосконалено* метод генерації наборів даних із зашумленою розміткою на основі параметричної моделі, що за рахунок генерації за-

шумленої розмітки для тренувальної вибірки та незашумленої розмітки - для тестової, дало можливість виконувати тестування впливу зашумлення розмітки на роботу нейромережових методів сегментації та класифікації.

- *удосконалено* модель нейронної мережі, що за допомогою додавання декодера класифікації що дає можливість побудувати методи багатозадачного навчання нейронних мереж та передбачення результатів.
- *удосконалено* методи багатозадачного навчання штучних нейронних мереж та передбачення результатів, що за рахунок об'єднання задач класифікації та сегментації, і введення обмеження другого роду (зверху) до функції втрат для задач з менш точною розміткою, дозволило підвищити достовірність сегментації умовах частково помилкової розмітки навчального набору даних в задачах автоматизованого скринінгу.

**Практичне значення одержаних результатів** полягає в наступному:

- створено параметричну модель наборів даних з зашумленою розміткою і методи їх генерації, що застосовується для тестування методів класифікації та сегментації в умовах частково-помилкової розмітки,
- розроблено нові методи навчання нейронних мереж, що дозволяє їх використання в задачах автоматизованого скринінгу,
- створено інструментальні засоби генерації наборів даних відповідно до розробленої параметричної моделі, а також навчання та передбачення нейронних мереж для задач автоматизованого скринінгу.
- на основі розроблених інструментальних засобів створено ефективні програмні модулі, які інтегровано з “хмарними” сервісами для вирішення ресурсомістких задач навчання нейронних мереж, що

забезпечує високу обчислювальну потужність та швидкість передбачення в задачах автоматизованого скринінгу.

### **Особистий внесок здобувача**

Всі наукові положення, висновки і рекомендації, що містяться в дисертації та виносяться на захист, отримано здобувачем самостійно в період з 2016 по 2020 рр. і узагальнено при оформленні дисертації. У статтях, написаних у співавторстві автору належать: модель нейронної мережі та метод багатозадачного навчання [2-4], модель нейронної мережі та метод підбору порогу класифікації [5], модель нейронної мережі та метод еволюції параметрів [6-8], алгоритм детекції полоси для лінійної камери [9], метод ідентифікації параметрів ковзання [11], метод розпізнавання спектрів [12-13]

### **Апробація результатів дисертації**

Основні положення і результати дисертації доповідалися на міжнародних конференціях Студентів і молодих науковців “Інформатика. Культура. Техніка” ІКТ-2016, ІКТ-2017, ІКТ-2018 (м. Одеса), міжнародній науковій конференції з методів розпізнавання патернів “ICPRAM-2020” (м. Валетта, Мальта, 2020), міжнародних студентських конференціях “Сучасні інформаційні технології” СІТ-2016, СІТ-2017, СІТ-2018 (м. Одеса).

Розроблені в роботі методи отримали **впровадження** в програмний продукт SafetyRadar компанії VITech Lab та в навчальний процес кафедри Інформаційних систем Інституту Комп’ютерних систем Одеського Національного Політехнічного Університету.

### **Публікації**

Основні результати дисертаційної роботи викладено в 13 публікаціях, з них: 8 статей у наукових фахових виданнях України з технічних наук, 1 стаття у зарубіжних наукових періодичних виданнях з напряму, з якого підготовлено дисертацію, що індексується наукометричною базою SCOPUS, 4 публікацій у працях і матеріалах наукових конференцій.



## **Структура і обсяг роботи**

Дисертація має загальний обсяг 168 сторінок і складається з вступу, чотирьох розділів, висновків, списку використаних джерел і 3 додатків. Основний текст дисертації викладено на 122 сторінках. Робота містить 59 рисунків і 17 таблиць. Список використаних джерел становить 114 найменувань